РЕФЕРАТ

Магістерська дисертація: 78 ст. , 10 рис., 51 табл., 18 джерел та? додатки.

Темою роботи ϵ "Теоретико-ігровий аналіз планувальників у гетерогенному багатопроцесорному середовищі".

Робота актуальна оскільки проблема ефективних обчислень існує та чимало досліджень проводиться у цьому напрямку із застосуванням різних підходів, у тому числі і теорії ігор.

Метою дослідження ϵ пошук рівновах та рішень гри множення матриць у розподіленому середовищі з двома користувачами. Спочатку потрібно побудувати модель множення матриці і для її перевірки розробити симуляційну систему, яка надасть можливість проводити експерименти значно швидше ніж у реальному хмарному середовищі.

Об'єктом дослідження ϵ планувальники типу extr-extr у розподіленому середовищі. Предмет дослідження - пошук рівноваг та інших оптимальних точок у грі одного та двох гравців.

Дослідження проводиться методом наукового моделювання процесу блочного множення матриці. За основу взята потокова модель, яка розглянута для неперервного випадку, і у подальшому звужена до дискретної моделі. На другому етапі дослідження проводяться експерименти за допомоги розробленої симуляційної системи, які дозволяють оцінити точність побудованої математичної моделі та дослідити гру на наявність рівноваг.

Новизна результатів полягає у тому, що розроблена симуляційна система, яка дозволяє проводити експерименти та досліджувати хмарне середовище за значно коротший час на простому комп'ютері. Також ця система дозволяє дослідити окремо кожну з компонент функції загального часу. Ще одною особливістю можна вважати універсальність, завдяки якій можна розширювати можливості симуляційної системи і таким чином моделювати більший набір задач.

Результати роботи:

- проведено аналіз планувальників extr-extr;
- розроблена симуляційна система для емуляції процесу множення матриць поблочно;

- розглянуті альтернативні підходи до вирішення проблеми: числові методи оптимізації, машинне навчання тощо.

Результати данної роботи можна використати при розробці системи розподілених обчислень з метою мінімізації часу виконання парелельних задач в умовах можливості регулювання складностей задач при розбитті їх на підзадачі. Подальші дослідження можуть бути проведені у напрямі аналізу стандартних операцій лінійної алгебри стантарта BLAS.

ПЛАНУВАЛЬНИКИ, МНОЖЕННЯ МАТРИЦЬ, ТЕОРІЯ ІГОР, ХМАРНІ ОБЧИСЛЕННЯ, РІВНОВАГА.

ABSTRACT

The thesis: 78 p., 10 fig., 51 tabl., 18 sources and? appendices.

The topic of this thesis is "Game theoretic analysis of schedulers in heterogeneous multiprocessor environment".

The work is relevant because the problem of efficient computing exists and many studies are conducted in this direction with the application of different approaches, including the theory of games.

The purpose of this study is to search for the equilibriums and solutions of the matrix multiplication game in a distributed environment with two users. Firstly, we need to build a matrix multiplication model and, for its testing, develop a simulation system that will allow you to experiment more quickly than in real cloud environments.

The research is carried out by the method of scientific modeling of the process of block multiplication of the matrix. This work is based on a fluid model, which is considered for a continuous case, is further reduced to a discrete model. At the second stage of the research, experiments are carried out with the help of the developed simulation system, which allow us to estimate the accuracy of the constructed mathematical model and to investigate the game for the presence of equilibrium.

The novelty of the results is that a simulation system is developed that allows you to experiment and explore the cloud environment in a much shorter time on a simple computer. Also, this system allows you to separately examine each component of the function of total time. Another feature is the universality through which you can expand the capabilities of the simulation system and thus simulate a larger set of tasks.

Thesis results:

- The model for a static scheduler of type extr extr is analyzed
- A simulation system was developed to emulate the process of multiplying matrices by block.
- other approaches to the problem are considered: numerical methods of optimization, machine learning, etc.

The results of this work can be used in the development of a distributed computing system in order to minimize the time of parelle tasks execution in

conditions of the ability to control the complexity of tasks when partitioning them into subtasks. Further research can be conducted in the direction of the analysis of standard operations of BLAS linear algebra standard.

SCHEDULERS, MATRIX MULTIPLICATION, GAME THEORY, CLOUD COMPUTING, EQUILIBRIUM.

3MICT

		Cı
ПЕРЕЛІК	СКОРОЧЕНЬ	10
	•••••	11
ворин 1		
	АНАЛІЗ ЗАДАЧІ ПЛАНУВАННЯ У ХМАРНОМУ СЕ-	
РЕДОВ	·	12
1.1		12
1.2		16
]	1.2.1 Сильні сторони	17
]	1.2.2 Слабкі сторони	18
	1.2.3 CloudSim Plus	19
1.3	Аналіз існуючих робіт	20
Ви	сновки до розділу	21
РОЗЛІЛ 2	ПОБУДОВА МАТЕМАТИЧНОЇ МОДЕЛІ МНОЖЕН-	
, ,	триць	22
2.1	,	22
2.2	•	24
2.3		27
2.4		29
2.5		30
	2.5.1 Алгоритм "Support enumeration"	32
	2.5.2 Алгоритм "Vertex enumeration"	33
2.6		5.
тn	иць для двох користувачів	33
2.7	•	36
-	сновки до розділу	38
розні п а		20
РОЗДІЛ 3	•	39
3.1		39
3.2		41
	3.2.1 Симуляція для одного користувача	41
	3.2.2 Аналіз штрафів за розбиття	43
	3.2.3 Симуляція для двої користувачів	47
3.3		50
Ви	сновки до розділу	52

РОЗДІЛ 4	Керування стартапом проекту	53
4.1	Опис ідеї проекту	53
4.2	Аналіз ринкових можливостей запуску стартап-проекту	57
4.3	Розробка ринкової стратегії проекту	66
4.4	Розроблення маркетингової програми стартап-проекту	70
Вис	сновки до розділу	74
висновк	и по роботі та перспективи подальших	
дослідж	ЕНЬ	76
ПЕРЕЛІК І	ПОСИЛАНЬ	77

ПЕРЕЛІК СКОРОЧЕНЬ

СПЗ - симуляційне програмне забезбечення

ОВ - обчислювальний вузол

ХС - хмарне середовище

ММ - множення матриць

ІМ - імітаційна модель

ОМ - обчислювальна мережа

ПП - програмний продукт

ВСТУП

Хмарні обчислення на даний момент вважається чимось достатньо простим да тоступним, деякі компанії навіть дозволяють безкоштовно викорустовувати певну кількість ресурсів, також університетам надаються ресурси для складних обчислень, які просто не можливо провести за допомоги звичайних комп'ютерів.

Планувальник у хмарних обчисленнях це те, що управляє самим процесом розподілення задач на обчислювальних вузлах, які виділені для розподіленої системи чи хмари. Саме від стратегії розподілення задач залежить як швидко користувачі отримають результати, наскільки справедливо буде розподілений час обчислень між багатьма користувачами та інші параметри.

Чимало досліджень виконано з метою проектування найефективнішого планувальника, проте такого ще не існує. Частіше за все для кожного з планувальників можна знайти перелік параметрів які він оптимізує. І все ще немає такого планувальника, який буде кращим за інший по всім параметрам та бути справедливим у середовищі з багатьма користувачами.

Основною метою цієї роботи є не розробка найкращого планувальника, а аналіз звичайних планувальників та характеристик задач, які будут краще всього розкривати потенціал вибраного планувальника. Також у роботі проведений ігровий аналіз процесу обчислення добутку двох матриць у розподіленому середовищі як гри двох користувачів із різними стратегіями розрізання матриці на блоки для паралельного обчислення добутку. Особливістю такої проблеми є те, що сам процес множення матриць при їх великих розмірах може займати дуже багато часу і тому в першчу чергу потрібно розробити симуляційне програмне забезпечення для більш швидкого аналізу моделей та алгоритмів.

РОЗДІЛ 1 АНАЛІЗ ЗАДАЧІ ПЛАНУВАННЯ У ХМАРНОМУ СЕРЕДОВИЩІ

1.1 Планувальники у розподілених обчисленнях

Планувальники в загальному поділяются на два типи: статичні та динамічні. Статичні мають певне правило розподілу задач на обчислювальні вузли та правило не зміюється під час роботи планувальника. Динамічні планувальники в свою чергу можуть адаптуватися під час роботи та змінювати стратегії планування. Хоч динамічні планувальники і здаються більш універсальними, проте вони дуже складні для аналізу та часто розробляються з метою оптимізації певного параметра.

Основною метою планування ϵ розподіл виконання задач, які надсилають користувачі, між обчислювальними вузлами. Планувальник форму ϵ чергу виконання задач, та визнача ϵ яку задачу на якому вузлі стартувати. Частіше за все користувачів хвилю ϵ лише мінімізація часу завершення деякої відправленої множини задач у хмару.

Структура хмари у загальному випадку описується за допомоги таких сутностей як:

- брокер
- планувальник
- дата центр
- хост
- віртуальна машина

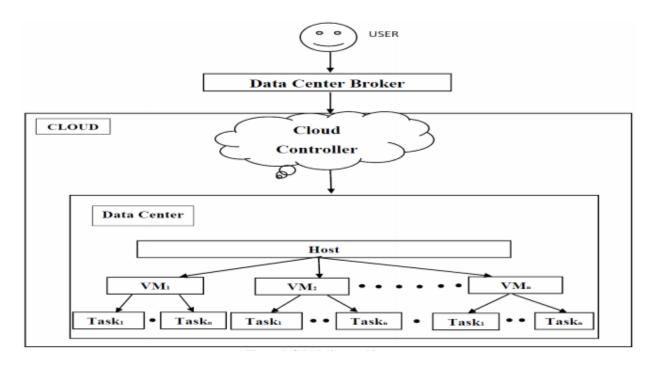


Рисунок 1.1 – Ілюстрація структури хмарної ОМ

На Рис. 1.1 проілюєтрована структура простої хмарної системи з одним сервером. Брокер являєься посередником між користувачем та хмарою і саме він формує запити до хмари на виконання задач та отримує результати їх виконання. Планувальник отримує задачі від брокерів різних користувачів та має свою певну стратегію розподілу черги задач, саме він керує дата центрами. Дата центри це несамостійні сутності і повністю керовані планувальниками. Їх основна мета - надавати обчислювальні вузли, запускати задачі по команді від планувальника та віддавати результати. Також у випадку динамічної хмари по певним запитам вони можуть збільшувати чи зменшувати кількість обчислювальних вузлів у мережі.

Віртуальна машина - це окремий обчислювальний вузол, який вміє лише отримувати вхідні дані, виконувати задачу та відправляти результат у дата центр. Часто буває таке, що декілька віртуальних машин працюють на одній фізичній машині, це звичайне явище, яке обумовлене тим, що дешевше на сервері із 64 чи 128 обчислювальними ядрами встановити багато віртуальних машин по 4 обчислювальних ядра. Часто користувачами не потрібні багатоядерні машини.

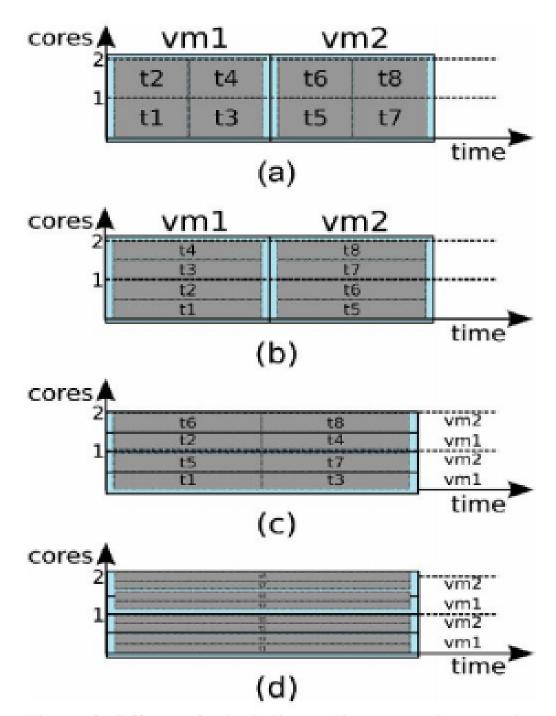


Figure 2. Effects of scheduling polices on task execution:
(a) Space-shared for VMs and Tasks, (b) Space-share for VMs and Time-shared for tasks, (c) Time-shared for VMs, Space-shared for tasks, and (d) Time-shared for both VMs and Tasks [7]

Рисунок 1.2 – Ілюстрація планування задач для time та space shared

Існує дві політики планування: space shared та time shared Рис. 1.2. У політиці space shared задачі у черзі розділяють між собою логічні ядра процесора обчислювального вулза і у випадку якщо усі ядра зайняті, то задач чекає звільнення ядра. Саме ця політика і вікористовується для тестування алгоритмів планування оскільки у випадку коли обчислювальні вузли мають лише одне ядро процесора, задачі виконуються послідовно від початку до кінця. Найпростіший алгоритм, який можна зустріти разом з політикою space shared - first come first served (FCFS).

Етапи роботи space shared політики:

- Крок 1 Формується черга задач
- Крок 2 Запланувати виконання наступної задачі із черги
- Крок 3 При завершенні задачі відправити результат
- Крок 4 Якщо черга непорожня, то повернутися на крок 2
- Крок 5 Кінець
 - *** Нові отримані задачі додаються до черги та очікують свого запуску свого виконання

Тіте shared політика в свою чергу означає що задачі у чергі розділяють між собою процесорний час. Тобто не обчислювальні ресурси, а проміжки часу які будуть витрачені на виконання кожної із задач. Усі задачі в черзі стартують в один і той самий час. Задача планувальника в цьому випадку вирішувати коли потрібно призупинити виконання одної задачі та стартувати чи продовжити виконання іншої задачі. На перший погляд ця політика значно краща оскільки дозволяє виконувати набір задач поступово, проте час переключення від одної задачі до другої також потрібно враховувати. А також щоб стартувати усі задачі потрібно мати вхідні дані для усіх задач, що також не завжди зручно. Разом з цією політикою часто можна зустріти посилання на алгоритм планування Round Robin.

Етапи роботи time shared політики:

- Крок 1 Формується черга задач.
- Крок 2 Усі задачі запускаються одночасно у режимі переключення між задачами за правилом, яке визначає планувальник
- Крок 3 Кінець

*** Нові отримані задачі додаються до черги та зразу запускаються і працюють у режимі спільного використання процесорного часу

З цього можна зробити висновки, що space shared політика задає послідовне виконання задач обчислювальними вузлами, а time shared - паралельне. Тіте shared політика рідко використовується у багатопроцесорних середовищах коли ОВ розташовані далеко один від одного. Також вона потребує спеціальної технології переключення між задачами, яка забечпечить дуже швидке переключення між задачами. Але такі технології зазвичай спеціалізовані і непридатні для виконання будь-яких задач.

У цій роботі використовується політика space shared отскільки саме вона передбачає виконання лише одної задачі на обчислювальному вузлі у кожен момент часу.

1.2 CloudSim як засіб для симуляції хмарних обчислень

Останнім часом технологія хмарних обчислень виникла як провідна технологія для забезпечення надійних, безпечних, відмовостійких, стійких та масштабованих обчислювальних послуг, які представлені як програмне забезпечення, інфраструктура або платформа як послуги (SaaS, IaaS, PaaS). Більше того, ці послуги можуть бути запропоновані в приватних центрах обробки даних (приватні хмари), можуть бути комерційно запропоновані для клієнтів (загальнодоступні хмари), або можливо, що як державні, так і приватні хмари об'єднуються в гібридні хмари.

Ця вже широка екосистема хмарних архітектур, разом із зростаючим попитом на енергоефективні ІТ-технології, вимагає своєчасних, повторюваних та контрольованих методологій для оцінки алгоритмів, програм і політики до фактичного розвитку хмарних продуктів. Оскільки використання реальних тест-сейфів обмежує експерименти до масштабу тест-сейфів і робить відтворення результатів надзвичайно важким завданням, альтернативні підходи для тестування та експериментів сприяють розробці нових технологій Cloud.

Підходящою альтернативою ϵ використання інструментів моделювання, що дають можливість оцінити хмарну систему перед розробкою програмного забезпечення в середовищі, де можна відтворити тести. Зокрема, у випадку обласного обчислення, коли доступ до інфраструктури здійснює платежі в реальній валюті, підходи на основі моделювання дають значні переваги, оскільки це дозволяє Cloud клієнтам протестувати свої послуги в повторимому та контрольованому середовищі безоплатно, а також настроювати продуктивність вузькі місця до розгортання на реальних хмарах. На стороні постачальника, симуляційні середовища дозволяють оцінити різні види сценаріїв лізингу ресурсів при різному розподілі навантаження та ціноутворення. Такі дослідження могли б допомогти постачальникам оптимізувати вартість доступу до ресурсів з упором на підвищення прибутку. За відсутності подібних імітаційних платформ, клієнти Cloud і постачальники повинні спиратися або на теоретичні та неточні оцінки, так і на підходи щодо спроб і помилок, які призводять до неефективної ефективності обслуговування та отримання доходу.

Основна мета цього проекту полягає у забезпеченні узагальненої та розширюваної системи моделювання, яка дозволяє безперешкодно моделювати, моделювати та експериментувати з розвиваються інфраструктурою Cloud Computing та додатковими службами. Використовуючи CloudSim, дослідники та розробники на базі промисловості можуть зосередити увагу на конкретних проблемах дизайну систем, які вони хочуть досліджувати, не занепокоєні деталями низького рівня, пов'язаними з інфраструктурою та службами Cloud.

1.2.1 Сильні сторони

CloudSim фреймворк [1] достатньо широко охоплює хмарні системи та їх внутрішню структуру. Саме за його допомоги можна перед проектуванням хмарної інфраструктури спочатку провести симуляції та перевірити адекватність спроектованої архітектури мережі.

Пакет працює на базі подій і усі процеси, що моделюються за допомогою CloudSim, реєструються як події. Також як і запит на створення обчислювального вузла, запит на виконання задач та інші. Це дозволяє додавати нові елементи у симуляційну систему без змін в існуючих файлах, потрібно лише створити свою власну подію та додати її обробку до сутностей, в яких ця подія відбувається. Додаваня обробки події часто виконується через наслідування від основного об'єкта та імплементації метода "processEvent".

Така система дуже гнучка та дозволяє швидко написати свою власну симуляцію.

1.2.2 Слабкі сторони

СПЗ CloudSim написане на мові програмування Java та непридатне для моделювання ситуацій з великою кількістю задач. Це одна із проблем, яка і привела до написання власної упрощеної версії СПЗ на мові С++, яка скоритила час симуляцій майже в 50 разів у порівнянні з модифікованою версією СПЗ, яка була написана на базі CloudSim та була майже у 150 разів швидшою за звичайну версію.

Також сама по собі мова Java неадекватно працює у випадку коли потрібно швидко створики велику кількість малих об'єктів, провести з ними певні операції та видалити.

Наприклад, для симуляції множення двох матриць N*N та N*N, при розмірі розрізання n=1 для одного користувача буде створено N*N задач множення підматриць розмірів 1*N та N*1. Звісно цей приклад не має сенсу оскільки розрізання n=1 скоріше за все не ефективне, проте сама неможливість його змоделювати для N=5000 вважається великим недоліком, оскільки поставивши N=50000 та n=10 отримаємо таку ж саму кількість задач, і лише на їх створення на мові Java витрачається більше 5 секунд. У той час как симуляція, написана на мові C++ дозволяє за ці 5 секунд провести 2 симуляції з такими ж параметрами.

Також слід зазначити, що першою спробою написання симуляції для цієї роботи було саме використання CloudSim. Проте під час розробки про-

грами доводилось дуже довго вивчати документацію і виправляти деякі внутрішні недоліки. Наприклад, у системі була знайдена проблема, що велика кількість малих задач оброблялась повністю і обривалась у випадковому місці. Це пов'язано з тим, що система не розроблялась з метою проведення важких симуляцій.

Також під час проведення симуляцій на виправленій версії системи було помічено дуже повільну швидкість симуляцій для великої кількості задач. Було знайдено 2 основні точки, які сильно сповільнювали програму та виправлені. Одна із правок дала пришвидшення симуляцій приблизно у 50 разів, а друга ще у приблизно 100 разів. Проте навіть з цими правками симуляції проходять значно повільніше за написаний нами самуляційний пакет.

1.2.3 CloudSim Plus

CloudSim Plus [2] це фреймворк, що є удосконаленою версією CloudSim та все ще розвивається, на відміну від свого батька, який не має оновлень з 2016 року. Оскільки пакет розробляється великою кількістю людей у їх вільний час, то довіра до нього сильно падає. Немає ніякого контролю якості системи, особливо ігнорується швидкодія. Також цей пакет може містити помилки у коді, які виправити сторонньому користувачу буде дуже важко, оскільки для цього протрібно знати та розуміти архітектуру саме цього пакета.

Проте саме цей пакет дозволяє проводити симуляції паралельно і на комп'ютерах з декількома ядрами можна отримати пришвидшення набору симуляцій за рахунок паралельного їх запуску. Саме це і було зроблено у першій версії симуляційного пакету. Але швидкодії всеодно було недостатньо, оскільки бажаним результатом було отримати симуляційну систему, яка швидко зможе проводити симуляції усіх можливих комбінацій стратегій двох гравців. І навіть для розміру матриць 1000 симуляція усіх комбінацій проходила більше години

1.3 Аналіз існуючих робіт

У роботі [3] проведений короткий аналіз стратегій виділення ресурсів типів Міп-Міп та Мах-Міп. Також у цій роботі занадто проста схема задач, складність обчислень прямо пропорційна розмірам файлів, що буває дуже рідко для трудоемних задач. Ця робота проводить симуляції, в яких кількість задач не більше 10 та всього 2 обчислювальних вузла. Проте вони запропонували алгоритм вибору, який покращує звичайну реалізацію стратегії виділення ресурсів. Також у цій роботі був використаний пакет CloudSim як основний засіб для аналізу та перевірки теорії.

Також цікавою роботою є використання теорії керування з метою мінімізації часу на виконання задачі заданого набору задач [4]. У цій роботі використовується time shared політика планування та динамічне переключення між виконанням задач. Для цього використовується теорія оптимального керування, яка керує кількістю часу, яка надається для задачі у наступній ітерації. Також доведена еквівалентність задачі планування і задачі оптимального управління часом.

Проблема ефективного множення великих матриць також розглянута у [5]. У цій роботі розглядають більш стандартизовану операцію над матрицями: C := A*B+C. Ця операція є основною у бібліотеках стандарту BLAS (Basic Linear Algebra Subprograms), яка в них називається GEMM (General Matrix Multiply) та описується як $C = \alpha A*B+\beta C$. Робота базується в першу чергу на [6] та [7], я яких проводиться аналіз складності вводу та виводу у випадку множення матриць і також можливі оптимізації, які можна застосувати у розподіленому середовищі з метою зменшення затрат на операції передачі даних. Ця проблема також випливає і у нашому дослідженні, оскільки показано, що надлишковість передачі даних при розбитті матриць на блоки дуже швидко зростає, проте найбільш оптимальними розбиттями є саме розбиття на малі блоки так як вони мінімізують простоювання вузлів при завершенні виконання блоку задач. Дослідження у роботі виконані саме для випадку блочного розбиття матриць і не підходять для паралельної версії алгоритма Штрассена.

Одна з свіжих робот на тематику ефективного множення матриць це [8]. В роботі розглядається операція y:=Ax для матриці $A\in\mathbb{R}^{m*n}$ та вектора $x\in\mathbb{R}^n$ як частковий випадок множення двох матриць. Побудована модель обчислень також включає дві схеми: Uncoded Load Balanced (ULB) та Coded Equal Allocation (CEA). Особливістю роботи є оцінка оптимальної конфігуляції обчислювального середовища на базі Amazon AWS завдяки побудові моделі. Знаходиться компроміс між вибором набору кластерів із заплопонованих тарифних планів та швидкістю виконання операцій. Для пошуку оптимальної конфігурації запропонований еврестичний пошук. На основі цієї роботи була запропонована покращена схема кодування та проведені порівняння з існуючими [9].

Висновки до розділу

У цьому розділі було розглянуто структуру принципи роботи об'єкта дослідження - хмачного середовища. ХС у наші дні це дуже поширейний інструментр для виконання задач користувачів будь-якої складності та вважається, що воно замінить у певному сенсі домашні обчислювальні машини.

Розглянуті популярні засоби для симуляції хмарного середовища - CloudSim, CloudSim Plus та GridSim. Ці засоби дуже популярні та часто використовуються у бакалаврських чи магістерських роботах для тестування спроектованих планувальників. Ці СПЗ не підходять для даної роботи оскільки вони написані на мові Java та мають низьку швидкодію у випадку великої кількості задач.

Із огляду літератури можна зробити висновнки, що тема актуальна і нові дослідження проводяться навіть для таких простих задач як множення матриць чи добутку матриці на вектор.

РОЗДІЛ 2 ПОБУДОВА МАТЕМАТИЧНОЇ МОДЕЛІ МНОЖЕННЯ МАТРИЦЬ

2.1 Потокова модель задачі множення матриць

Нехай система складається з m обчислювальних вузлів та кожен з них характеризується швидкістю роботи $p_i, i=1,\ldots,m$ — тобто кількістю операцій з плаваючою точкою за секунду, які він може здійснити. Процесори з'єднані лініями зв'язку з планувальником, який передає задачі та приймає від них результат. Будемо вважати, що лінії зв'язку ідентичні та мають швидкість передачі даних q та затримку l. Будемо вважати, що виконуються наступні припущення

- Всі процесори починають роботу одночасно
- Планувальник здійснює призначення миттєво

Нехай задані дві квадратні матриці розмірності $N\times N$, результат множення яких необхідно обчислити. При використанні блочного алгоритму користувач задає розмір блоку n, в результаті чого формуються $k=\frac{N^2}{n^2}$ задач, кожна з яких буде мати складність $\mathcal{O}(n^2)$. Припустимо, що планувальник забезпечує пересилку повідомлень на вузли за певним фіксованим алгоритмом, який завершує обчислення за час T(N,n). Тоді задача користувача полягає у пошуку мінімуму функції:

$$T(N,n) \longrightarrow \min$$
 (2.1)

Функція T(N,n) може мати багато локальних мінімумів в залежності від конфігурації системи. Ілюстрації графіків функції, отриманої шляхом симуляції, наведені у експериментальній частині та корелють з отриманими результатами у [10].

Одним з розповсюджених підходів до аналізу таких задач полягає у дослідженні потокової моделі даного процесу [11].

Припустимо, що користувач вибрав вектор $x\in\mathbb{R}$ з компонентами x_i , де $x_i>0$, $x_i\leq k,$ $i=1,\ldots,m,$ $\sum_{i=1}^kx_i=k.$ Всі таки вектори утворюють мно-

жину X(n). Кожен компонент вектора x описує відсоток задач, призначених для виконання на i-тому процесорі. Будемо брати до уваги тільки операції, множення. Таке спрощення дозволяє у явному вигляді виписати функції часу. Загальний час закінчення залежить від x, та дорівнює:

$$T(x, X(n)) = \max_{i=1,\dots,m} \frac{x_i N n^2}{p_i}$$
 (2.2)

Потокова модель передбачає можливість розділення задачі на підзадачі розміру $\epsilon=Nn^2$, компонування з них підходящих підзадач та визначення загального часу при $\epsilon\longrightarrow 0$.

Твердження 1. Мінімальний час обчислень для потокової моделі з одним користувачем дорівнює:

$$T = \frac{N^3}{\sum_{i=1}^{m} p_i} \tag{2.3}$$

Згізно з цим користувач має розділити задачі так, щоб вузол i отримав задач з сумарною складністю $p_i * T$ часу.

Функція Мінковського для множини X та вектора $p \in \mathbb{R}^m$ визначається наступним чином:

$$\mu_X(p) = \inf \lambda > 0 : p \in \lambda X \tag{2.4}$$

Відомо, що ця функція опукла для опуклої X. Визначимо множину потужностей системи $R=r\in\mathbb{R}^m: r_i\in[0,p_i]$ та масштабуємо її наступним чином:

$$R(n) = \frac{R}{Nn^2} \tag{2.5}$$

Тоді $T(x,X(n))=\mu_{R(n)}(x).$

Доведення.

Розглянемо праву частину: $\mu_{R(n)}(x)=inf\lambda>0: x\in\lambda R(n)$ Умова належності вектора x множині R записується як $\max_{i=1,\dots,m}\frac{x_iNn^2}{p_i}$,а значить

 $\mu_{X(n)}(p)=\inf\{\lambda>0:\max_{i=1,\dots,m}\frac{x_i}{p_i}=\frac{\lambda}{Nn^2}\}.$ Або $\lambda=\max_{i=1,\dots,m}\frac{x_iNn^2}{p_i}.$ 3 властивостей функції $mu_{X(n)}(x)$ випливає, що мінімальний час $T_{min}=\min_{x\in X(n)}$ існує і єдиний. Для врахування пересилок та затримки з'єднання потрібно зазначити, що алгоритм надсилає $2x_iNn$ елементів (x_i пар матриць розмірів n*N) на відповідний вузол i та приймає x_i*n^2 елементів (x_i результатів множення матриць n*N та N*n).

Отже, сумарний час закінчення з урахуванням пересилок та затримок дорівнює:

$$T_s(x,X(n)) = \max_{i=1,\dots,m} \left\{ \frac{x_i N n^2}{p_i} + \frac{x_i (n^2 + 2Nn)}{q} + x_i l \right\} \tag{2.6}$$

Твердження 2. Існує мінімум часу по $x - \min_{x \in X(n)} T_s(x, X(n))$

2.2 Аналіз штрафів від величини розбиття

У цьому підрозділі ми проведемо аналіз того, як величина розбиття впливає на час виконання задач у потоковій моделі.

Як ми бачимо з 2.6, наявні 2 види штрафів від дрібності розбиття. Перший вид з'являється через надлишковість передачі даних при розбитті матриці на підматриці, а другий напряму від кількості задач, що утворились в результаті розбиття.

Пронормуємо x_i :

$$d_i = \frac{x_i}{\sum_{i=1,\dots,m} x_i} = \frac{x_i}{k}$$
 (2.7)

Таким чином d_i це доля обчислень вузла $i,d_i\in[0,1],\sum_{i=1,\dots,m}d_i=1.$ I навпаки, $x_i=d_i*k=d_i*\frac{N^2}{n^2}$

Перепишемо 2.6 за допомоги d_i :

$$T_s(x, X(n)) = \max_{i=1, \dots, m} \left\{ \frac{d_i k N n^2}{p_i} + \frac{d_i k (n^2 + 2Nn)}{q} + d_i k l \right\} \tag{2.8}$$

Проте нас більше всього цікавить рівняння із заміною $k = \frac{N^2}{n^2}$.

$$T_s(x,X(n)) = \max_{i=1,\dots,m} \left\{ \frac{d_i \frac{N^2}{n^2} N n^2}{p_i} + \frac{d_i \frac{N^2}{n^2} (n^2 + 2Nn)}{q} + d_i \frac{N^2}{n^2} l \right\} \qquad (2.9)$$

Після скорочення отримаємо:

$$T_s(x,X(n)) = \max_{i=1,\dots,m} \left\{ d_i \frac{N^3}{p_i} + d_i \frac{N^2(1+2*\frac{N}{n})}{q} + d_i \frac{N^2}{n^2} l \right\} \tag{2.10}$$

Позначимо за T_i час роботи вузла i, тоді:

$$T_i = d_i \frac{N^3}{p_i} + d_i \frac{N^2(1 + 2 * \frac{N}{n})}{q} + d_i \frac{N^2}{n^2} l$$
 (2.11)
$$T_s(x, X(n)) = \max_{i=1,...,m} T_i$$

Виділимо окремі складові T_i :

$$A_{i} = \frac{N^{3}}{p_{i}}$$

$$B_{i} = \frac{N^{2}(1 + 2 * \frac{N}{n})}{q}$$

$$C_{i} = \frac{N^{2}}{n^{2}}l$$

$$T_{i} = d_{i}(A_{i} + B_{i} + C_{i})$$
(2.12)

Таким чином ми розділили час виконання на 3 окремі складові, кожна з яких має свій сенс. Перша складова A_i відповідає за сумарну складність алгоритма множення двох матриць без розбиття. Друга складова B_i відповідає за надлишковість передачі даних і третя C_i за затримки.

Причому помітимо, що A_i ніяк не залежить від n. Тобто перша складова це завжди повна складність задачі множення цілих матриць і незалежно від розбиття складність блочного множення сумарно залишається незмінною.

Нехай фіксована конфігурація середовища, тобто $p_i, i=1,\dots,m$ задані та незмінні. У такому випадку при зміні розбиття долі обчислень вважаємо

незмінними, оскільки вони в першу чергу залежать від потужностей обчислювальних вузлів.

І для двох різних розбиттів $n_1,\,n_2:n_1< n_2$ ми маємо складові A_i однаковими, оскільки вони не залежать від розбиття.

$$\begin{split} n_1, n_2 &: n_1 < n_2 \\ A_i^{n_1} &= A_i^{n_2} = \frac{N^3}{p_i} \\ \frac{B_i^{n_1}}{B_i^{n_2}} &= \frac{1+2*\frac{N}{n_1}}{1+2*\frac{N}{n_2}} = \frac{n_2(n_1+2N)}{n_1(n_2+2N)} \\ \frac{C_i^{n_1}}{C_i^{n_2}} &= \left(\frac{n_2}{n_1}\right)^2 \end{split} \tag{2.13}$$

Візьмемо за $n_2=N$, оскільки як можна здогадатися, якщо ми матрицю не розрізаємо, тоді надлишковості немає. Тому будемо порівнювати випадок розрізання і множення цілої матриці на віддаленому вузлі. У такому випадку звісно з'являється проблема неефективного використання обчислювальної мережі, проте на даний момент нас цікавить дослідження надлишковості при множенні матриці блочно.

$$\begin{split} n_1, n_2 &: n_1 < n_2, n_2 = N \\ r_{n_1} &= \frac{N}{n_1} \\ \frac{B_i^{n_1}}{B_i^N} &= \frac{N(n_1 + 2N)}{n_1(N + 2N)} = \frac{n_1 + 2N}{3n_1} = \frac{1 + 2r_{n_1}}{3} \\ \frac{C_i^{n_1}}{C_i^{n_2}} &= \left(r_{n_1}\right)^2 \end{split} \tag{2.14}$$

Для наглядності побудуємо графік відношення $\frac{B_i^{n_1}}{B_i^N}$ для деяких віксованих N. Будемо брати $n_1 \in [50, N]$ щоб не мати проблем з маштабом оскільки при малих n_1 це відношення дуже велике.

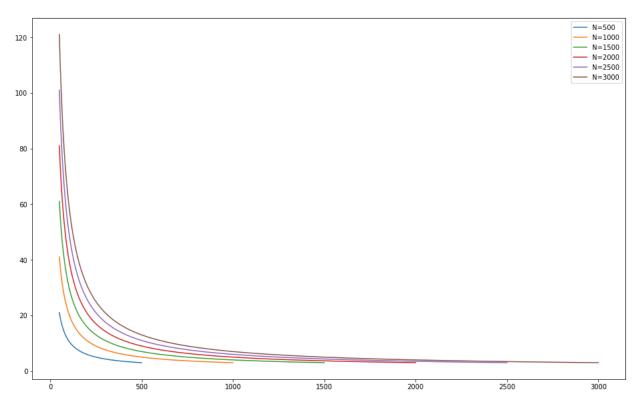


Рисунок 2.1 – Графік залежності відношення $\frac{B_i^{n_1}}{B_i^N}$ від $n_1 \in [50,N]$ при фіксованих N

2.3 Дискретна версія моделі обчислень множення матриць

Нехай розмір блоку n ϵ дільником N, тоді задача множення матриць N*N та N*N поділяється на $k=\frac{N^2}{n^2}$ паралельних задач множення матриць n*N та N*n. У порівнянні з потоковою моделю, дискретний варіант має скінченну множину комбінацій розподілу задач планувальником на обчислювальні вузли.

Визначимо множину Y(n) по аналогії з X(n):

$$Y(n) = \big\{ y \in R^m : y_i \in 0, \dots, k, \sum_{j=1}^m y_j = k, i = 1, \dots, m \big\} \tag{2.15}$$

Оскільки Y(n) це дискретний варіант X(n), то очевидне включення $Y(n)\subset X(n)$. Задача планувальника ϵ саме вибір конкретного вектора

 $y\in Y(n)$. У роботі досліджуються планувальники типу $extr_1extr_2$ - min min, min max, max min та max max. Принцип роботи їх дуже простий.

- 1 Формується черга задач
- 2 Із черги задач вилучається задача згідно з конфігурацією $extr_1$. min конфігурація вибирає задачу із черги з найменшою складністю, а max з найбільшою
- 3 Вилучена з черги задача надсилається на вільний процесор згідно з правилом extr2. min конфігурація має на меті виконати задачу за найкоротший час і вибирає вільний процесор з найбільшою потужністю, а max навпаки з найменшою
- 4 Якщо черга задач не пуста, то повернутися на крок 2 Твердження Для будь-якого n виконуються нерівності:

$$T_d(n) = \min_{y \in Y(n)} T(y, X(n))) \ge \min_{x \in X(n)} T(x, X(n)))$$
 (2.16)

Також варто пояснити саму суть пошуку найкращого розбиття. Основна проблема у тому, що для великих розбиттів планування може бути недостаньо рівномірно розподелене. Наприклад, розглянемо систему з трьома однаковими обчислювальними вузлами. Розбиття матриць на 2 підматриці буде недостатньо ефективно оскільки будуть сформовані 4 задачі. З з 4 задач виконаються повністю паралельно, але четверта буде виконуватись на одному вузлі, в той час як інші 2 будут простоювати. Саме для цього ми і намагаємося розрізати матриці на рівні малі шматки, щоб такої проблеми не виникало. Проте через наявність штрафів за пересилку за затримок дуже малі розбиття також не підходять оскільки штрафи стають занадто великими.

Також з граничних випадків можна розгянути такий, при якому $q=\inf$ та l=0. Таку ситуацію можна зустріти при обчисленні добутку матриць на одному комп'ютері з кількома ядрами. Саме для цього випадку очевидно, що найкращою стратегією буде розрізати на найменші шматки. Таким чином буде мінімізований час простою при виконанні останніх задач з черги.

2.4 Визначення з теорії ігор

Нехай задана гра для n осіб (S,f), де S - профіль стратегій $S=S_1\times S_2\times \ldots \times S_n$ та f - функція виграшу $f=(f_1(x),f_2(x),\ldots,f_n(x))$ для $x\in S$.

Для деякого набору стратегій гравців $x \in S$ позначимо за x_{-i} вектор x без складової i, тобто стратегіями усіх гравців крім i-го.

Для i-го гравця кажуть, що x_i^1 домінує $x_i^2, x_i^1, x_i^2 \in S_i$, якщо $f_i(x_i^1, x_{-i}) > f_i(x_i^2, x_{-i}), x_{-i} \in S_1 \times S_2 \times \dots S_{i-1} \times S_{i+1} \times \dots \times S_n$. Також кажуть, що x_i^2 домінована x_i^1 . Також домінування може бути нестрогим, для цього у визначенні потрібно використовувати нестрогу нерівність.

Таблиця 2.1 – Проста гра двох осіб у матричній формі

	1	2	3
1	1,2	2,2	3,5
2	2,1	3,4	4,3
3	3,5	3,7	5,8

Простіше за визначення демонструвати для ігор двох гравців, оскільки їх можна представити у вигляді матриць ??. У ній для першого гравця стратегія "2" домінує "1" та стратегія "3" нестрого домінує "2". Домінуючі стратегії допомагають при аналізі гри, оскільки фактично домінування одної стратегії "А" над "Б" дозволяє не розглядати стратегію "Б" у подальшому. У випадку раціональності гравця він ніколи не вибере доміновану стратегію.

Неформальне визначення рівноваги за Нешем звучить так: у точці рівноваги жоден з гравців не може збільшити свій виграш шляхом вибору іншої стратегії при фіксованих стратегіях інших гравців.

Запишемо формальне визначення рівноваги за Нешем.

 x^* є рівновагою за Нешем якщо:

$$\forall i, x_i \in S_i : f_i(x_i^* m x_{-i}^*) > f_i(x_i, x_{-i}^*) \tag{2.17}$$

Найпопулярнішою демонстрацією рівноваги за Нешем ϵ дилема в'язня.

Таблиця 2.2 – Ілюстрація дилеми в'язня як гри у матричній формі

	Співпраця	Зрада
Співпраця	2,2	10,1
Зрада	1,10	5,5

Таблиця ?? показує типове визначення дилеми в'язня. У таблиці записані програші учасників, тобто кожен з них намагається мінімізувати свій програш і таким чином максимізувати виграш.

Пояснюється за ситуація тим, що двох в'язнів запитують про свідчення проти спільника. Якщо один в'язень надає свідчення про іншого, то йому трохи вкорочують строк перебування у в'язниці, а другому навпаки збільшують. Також якщо вони обидва будуть мовчати, то їм однаковий строк, який відносно виглядає оптимально порівняно з іншими. Проте якщо вони обидва будуть свідчити, то їм обом строк 5 років.

Як можна побачити з матриці, домінуючих стратегій немає. Проте є рівнована за Нешем. Рівновага у парі стратегій ("Зрада", "Зрада"). Найцікавіше тут те, що точка рівноваги показує програші значно більші ніж у стратегії ("Співпраця", "Співпраця"). Проте логіка при розгляданні рівноваги за Нешем полягає у пошуку найкращої відповіді на певну фіксовану стратегію опонента.

Ще одне неформальне визначення рівноваги за Нешем ϵ "найкраща відповідь на найкращу відповідь".

Особливу увагу надають цій рівновазі саме через її застосування у теорії конфліктних ситуацій, оскільки саме точки рівноваги за Нешем часто описують ситуації, з яких важко вийти. Причому вихід з таких ситуацій не вигідний нікому, хоч і існують інші точки у грі, які можуть мати значно більші виграші.

2.5 Числові методи знаходження рівноваг Неша

Для гри двох гравців визначені деякі методи знаходження рівноваг Неша. У [12] проводиться аналіз складності задачі пошуку рівноваг, та дове-

дено, що пошук це задача PPAD складності - "Polynomial Parity Arguments on Directed graphs". Це випливає в першу чегру з того, що рівновага Неша обов'язково існує у мішаних стратегіях. Задачі PPAD характеризуються саме тим, що їх розв'язок обов'язково існує, хоч його і складно знайти.

У книзі [13] описані алгоритми для знаходження рівноваг і основними з них ϵ "Support enumeration" та "Vertex enumeration". Опишемо їх.

Основні визначення.

Мішаною стратегією гравця з профілем стратегій S називають вектор $k=\dim S, x\in R^k: 0\leq x_i\leq 1, \sum_{i=1}^k x_i=1.$ Тобто гравець вибирає чисті стратегії із S з ймовірностями $x_i.$ Носієм мішаної стратегії x назовемо множину $T=\{i: x_i>0\}.$

Біматричною грою назовемо гру двох осіб у матричній формі, де номера строк відповідають за стратегії першого гравця, а номера колонок за стратегії другого. Позначимо профілі стратегій гравців за $S_1,S_2:\dim S_1=m$, $\dim S_2=n$. Тоді виграші задаються двома матрицями $A,B\in\mathbb{R}^{m*n}$ для гравця 1 та 2 відповідно.

Найкращою відповіддю (best response) гравця 1 на мішану стратегію гравця 2 y ϵ такая мішана стратегія x, що максимізу ϵ його очікуваний виграш: x^TAy . Аналогічно визначається найкраща відповідь гравця 2 мішана стратегія y на мішану стратегію гравця 1: $y: x^TBy \to \max$.

Визначення рівноваги Неша у мішаних стратегіях:

$$x,y$$
 — мішані стратегії гравців 1 та 2 відповідно : x — найкраща відповідь гравця 1 на y (2.18) y — найкраща відповідь гравця 2 на x

Тобто повторюється одне з визначень рівноваги за Нешем - "найкраща відповідь на найкращу відповідь".

Запишемо визначення найкращої відповіді у більш зручному вигляді для подальших описів алгоритмів. Нехай x,y - машані стратегії гравців 1 та 2 відповідно, тоді:

$$M=1,\ldots,m$$
 $\left(x$ найкраща відповідь на стратегію $y\right)\Leftrightarrow$ $\left(\forall i\in M: x_i>0\Rightarrow (Ay)_i=u=\max\{(Ay)_k|k\in M\}\right)$

Доведення цього факту дуже просте:

$$\begin{split} x^TAy &= \sum_{i=1}^m x_i (Ay)_i = \sum_{i=1}^m x_i (u - (u - (Ay)_i)) = \\ &= u - \sum_{i=1}^m x_i (u - (Ay)_i) \end{split} \tag{2.20}$$

3 2.20 ми маємо, що $x^TAy \leq u$ оскільки $x_i \geq 0$ та $u - (Ay)_i \geq 0 \forall i = 1, \ldots, m$. Рівність досягається тільки у випадку виконання імплікації $x_i > 0 \Rightarrow (Ay)_i = u$. Аналогічно до $u = \max\{(Ay)_k | k \in \{1, \ldots, m\}\}$ визначається і $v = \max\{(x^TA)_k | k \in \{1, \ldots, n\}\}$.

Гру називають недегенеративною, якщо в ній не існує такої мішаної стратегії з носієм потужності k, на яку є більше ніж k кращих відповідей у чистих стратегіях. Якщо це не виконується, то гру називають дегенеративною.

Також є тверження, що для будь-якої рівноваги Неша (x, y) у недегенеративній біматричній грі x та y мають однакові розмірності носіїв.

Саме завдяки цим фактам і з'явився метод "Support enumeration".

2.5.1 Алгоритм "Support enumeration"

Позначимо за $M=1,\ldots,m,N=1,\ldots,n$ та $l=\min\{m,n\}.$ Для $k=1,\ldots,l$:

- 1. Вибираємо наступну пару підмножин $I \subset M, J \subset N$.
- 2. Розв'язуємо систему $\sum_{i\in I} x_i b_{ij} = v$ для $j\in J$ та з обмеженням $\sum_{i\in I} x_i = 1.$

- 3. Розв'язуємо систему $\sum_{j\in J} a_{ij} y_j = u$ для $i\in I$ та з обмеженням $\sum_{j\in J} y_j = 1.$
- 4. Перевіряємо, що $x \ge 0$ та $y \ge 0$ і виконується 2.19.

Таким перебором ми в шукаємо усі можливі пари рівноваг у мішаних стратегіях з різними потужностями носіїв починаючи з 1, тобто рівноваг у чистих стратегіях. Проте метод працює дуже довго навіть для малих матриць, оскільки переборів різних комбінацій проводиться дуже багато. Фактично потрійний цикл з вирішенням систем лінійних рівнянь для кожної пари.

2.5.2 Алгоритм "Vertex enumeration"

Цей алгоритм базується на теорії політопів. Вводяться такі політопи: $P = \{x \in \mathbb{R}^n | x \geq \mathbf{0}, B^T x \leq \mathbf{1}\}$ та $Q = \{y \in \mathbb{R}^m | Ay \leq \mathbf{1}, y \geq \mathbf{0}\}$. Ці політопи мають повну розмірність оскільки припускається, що A, B^T мають невід'ємні елементи та не мають повністю нульових стовбчиків.

Алгоритм проходить по усім парам вершин x з $P - \{\mathbf{0}\}$ та y з $Q - \{\mathbf{0}\}$. Якщо пара (x,y) повністю пронумерована, то це рівновага за Нешем. Повністю пронумерована значить, що усі значення з множини $M \cup N$ зустрічаються у при номерах координат x чи y.

2.6 Некооперативна ігрова модель планування множення матриць для двох користувачів

Сформулюємо концепції гри між двома гравцями, бажання яких ϵ виконання задачі множення матриць у розподіленому середовищі з паралелізацією методом розбиття матриць на блоки.

Некооперативна гра описує процес прийняття рішення про розбиття двома гравцями в умовах конфлікту інтересів. Некооперативність полягає у тому, що немає зовнішніх причин до їх співпраці, проте в самій грі з певною структурою може виникати співпраця гравців.

Нехай у загальному випадку ця гра проводиться між гравцями $u_i, i=1,\ldots,L$. Усі гравці мають рівний доступ до розподіленого середовища з потужностями обчислювальних вузлів $p_i, i=1,\ldots,m$ через спільний інтерфейс планувальника. Також передача даних для множення підблоків проходить по каналам з пропускними здатностями q та затримкою l. Кожен з гравців може зареєструвати певний набір задач і після цього чекати на результат. Часом для гравця u_i будемо вважати час повернення результата усіх відісланих ним задач, тобто момент, коли він отримає останній блок матриці результата.

Для гравців заданий розмір N і їх задача порахувати у розподіленому середовищі добуток матриць N*N та N*N. Стратегіями гравців називаемо $n_i \in [1,N]$ які визначають розмір блоку розбиття.

Кожен гравець хоче виконати паралельне множення матриць якможна швидше. Конфлікт полягає у тому, що зміна стратегії розбиття одним гравцем може покращити його час, проте значно погіршити час другого гравця.

Виділяють гравців раціональних та нераціональних. Дії раціонального гравця спрямовані на максимізацію його виграшу. Нераціональні можуть вносити хаос випадковими ходами. Вважатимемо, що гравці у цій грі раціональні.

Для спрощення будемо вважати, що виконуються такі припущення:

- Страгерії користувачів $n_i, i=1,\ldots,k$ впорядковані за зростанням
- Стратегії користувачів n_i є дільниками N
- У випадку, якщо користувачі вибрали однакове розбиття, то їх час завершення однаковий та дорівнює подвноєному індивідуальному часу
- Існує єдиний мінімум $T_d(n_j), j=1,\dots,k$. Позначимо індекс, при якому досягається мінімум за j^*

Розглянемо планувальники min-min та min-max.

Нехай користувачі вибрали розрізання n_1,n_2 , які являються їх стратегіями у грі. Користувачі відправляють свої задачі, та отримують результати. Часи повернення усіх задач позначимо за $T_1(n_1,n_2),T_2(n_1,n_2)$, які ϵ власне програшами користувачів.

Враховуючи специфіку планувальників помітимо такі властивості часів повернення від розрізань:

- Якщо $n_1 < n_2$, то виграш першого користувача дорівнює $T_d(n_1)$, а другого $T_d(n_1) + T_d(n_2)$
- Якщо $n_1>n_2$, то виграш першого користувача дорівнює $T_d(n_1)+T_d(n_2),$ а другого $T_d(n_2)$
- Якщо $n_1=n_2$, то виграші користувачів однакові та дорювнюють $2T_d(n_1)$

Такі властивості з'являються через те, що ці планувальники пріорітезують задачі з меншим обзягом роботи і тому користувач, який вибрав розрізання менше, повністю окупує обчислювальні ресурси. Задачі другого користувача підуть на виконання лише після того як усі задачі першого користувача будуть вилучені з черги очікування. Це явище і породжує конфлікт між двома гравцями, оскільки кожен з них хоче мінімізувати свій програш - час виконання власних задач. Пороте у минулих підрозділах ми розглянули форму штрафів для різних розбиттів і зменшувати розмір розбиття починаючи з деякого момента вносить дуже великий штраф за пересилання. Особливо це помітно у випадках коли ми розглядаємо розбиття n:n:n:n

Тверження.

Нехай виконується нерівність

$$2T_d(n_{j^*}) \le T_d(n_{j^*-1}) \tag{2.21}$$

тоді пара стратегій (n_{j^*}, n_{j^*}) - рівновага Неша.

Доведення.

Розглянемо стратегію (n_{j^*}, n_{j^*}) у випадку якщо нерівність 2.21 виконується, тоді отримуємо такі факти:

- 1. За властивостями планувальника якщо будь-який з користувачів змінить свою стратегію на $n:n>n_{j^*}$, тоді його програш тільки збільшиться, оскільки тоді перший користувач буде мати розмір розрізання менший і його виконані задачі в першу чергу.
- 2. При зміні стратегії на n_{j^*-1} користувач виграє право першочергового виконання саме його набору задач, проте завдяки нерівності 2.21 ця зміна стратегії не зменшить його програш.
- 3. При зміні стратегії на $n:n < n_{j^*-1}$ штрафні частини функції часу вже більше впливають на час і тому у реальних випадках ці стратегії дадуть

значно більший штраф. Цей ефект краще всього буде проілюстровано у практичній частині в наведеній таблиці окремих компонент часу виконання в залежності від розбиття.

Наслідок.

Отримана рівновага Парето неефективна, оскільки $T_1(n_{j^*},n_{j^*}) < T_1(n_{j^*-1},n_{j^*-1})$ та $T_2(n_{j^*},n_{j^*}) < T_2(n_{j^*-1},n_{j^*-1}).$

2.7 Імплементація імітаційної моделі

IM дозволяє симулювати процес множення матриць у розподіленому середовищі враховуючи як час на власне обчислення так і передачу даних.

Розглянемо задачу множення двох N*N матриць М1 та М2. Позначимо за n кількість рядків матриці М1 та відповідно стовбців матриці М2. Таким чином отримуємо 2 підматриці n*N та N*n які і формують одну задачу, що буде відіслана планувальнику. Таких задач буде $\lfloor \frac{N}{n} \rfloor \times \lfloor \frac{N}{n} \rfloor$. Проте в обох матрицях М1 та М2 у випадку якщо п не дільник N буде залишок рядків М1 та стовбців М2 відповідно. Позначимо розмір залишка за . Тому до основних задач ще потрібно додати задачі множення матриць m*N та N*m і одну задачу множення m*N та N*m.

Тобто задача множення матриць N*N та N*N розбивається на такі підзалачі:

- $\lfloor \frac{N}{n} \rfloor imes \lfloor \frac{N}{n} \rfloor$ множень матриць n*N та N*n
- $\lfloor \frac{N}{n} \rfloor$ множень матриць m*N та N*n
- $\lfloor \frac{N}{n} \rfloor$ множень матриць n*N та N*m
- 1 множення матриць m*N та N*m

Множення матриць N1*N2 та N2*N3 потребує N1*N3*N2 операцій множення та N1*N3*(N2-1) операцій додавання. Позначимо за AM коефіцієнт складності операції множення по відношенню до операції додавання. Тоді складність множення матриць N1*N2 та N2*N3 можна виразати у одиницях операцій додавання як:

$$Complexity(N1, N2, N3) = N1 * N3 * (N2 * AM + N2 - 1)$$
 (2.22)

Позначивши потужність OB за P (кількість операцій додавання / секунду) та складність задачі C (кількість операцій додавання) отримаємо час, який OB витратить на обчислення задачі C:

$$T_{processing} = \frac{C}{P} \tag{2.23}$$

Також для множення матриць N1*N2 та N2*N3 потрібно переслати N1*N2+N2*N3 елементів до обчислювалюного вузла, та отримати результат у розмірі N1*N3 елементів. Час на передачу даних обчислюється таким чином:

$$T_{transfer} = latency + \frac{N1*N2 + N2*N3 + N1*N3}{bandwidth}$$
 (2.24)

де latency визачає затримку між відправленням пакета від користувача до планувальника та bandwidth пропускну здатність між користувачем та планувальником.

Загальний час на обробку задачі отримується з урахуванням 2.23 та 2.24:

$$T = T_{processing} + T_{transfer} (2.25)$$

Для двох гравців вибираються n_1 та n_2 , формуються задачі, додаются в загальний список та випадково перемішуются і подаются на планувальник. Час для кожного з гравців визначається як час повернення від планувальника до гравця останьої його задачі.

Висновки до розділу

У розділі побудована модель задачі множення матриць у гетерогенному розподіленому середовищі для одного та двох користувачів з урахуванням штрафів за пересилки та затримок. Запропонована потокова модель, яка спочатку сформульована для неперервного випадку, а потім звужена до дискретного. Таким чином модель дуже точно дозволяє оцінити час виконання задач у розподіленому середовищі.

Розглянуті базові визначення з теорії ігор та представлені числові методи по знаходженню рівноваг Неша у біматричній грі. Базовий метод "Support enumeration" простий у розумінні, проте складний в сенсі обчислювальної складності. Другий розглянутий метод "Vertex enumeration", який дозволяє більш ефективно перебирати можливі пари стратегій для перевірки їх на рівновагу.

Проведено аналіз ігрової задачі множення матриць двома користувачами у спільному гетерогенному розподіленому середовищі. Сформульовано тверження, яке потрібно перевірити практично на побудованій симуляційній системі.

РОЗДІЛ З АНАЛІЗ РЕЗУЛЬТАТІВ СИМУЛЯЦІЙ

3.1 Структура симуляційного програмного забезпечення

Програма написана на мові C++ та умовно поділяється на дві логічні частини: модуль обробки параметрів та модуль симуляції.

Модуль обробки параметрів дозволяє задавати розмір матриць, режим одноно гравця чи двох, межі перебору стратегій розрізання, параметри планувальника, характеристики обчислювальних модулів, параметрів мережі — bandwidth та latency без перековпіляції програми через параметри командного рядка.

Модуль симуляції генерує задачі для кожного з користувачів, зливає їх в один список та власне подає їх на симулятор, який повертає оброблені задачі з проставленими змінними часу початку та завершення роботи над задачею і номером обчислювального вузла, який обробляю цю задачу.

Етапи роботи симулятора:

- 1. Перемішування списка очікуючих задач з метою емуляції отримання задач у випадковому порядку.
- 2. Сортування списка очікуючих задач по складності у відповідності до пріорітетності задач та списка обчислювальних вузлів по потужності у відповідності до пріорітетності обчилювальних вузлів. Наприклад для тіптах планувальника список очікуючих задач буде відсортованим від простої до складної, а список обчислювальних вузлів від потужного до повільного.
- 3. Ініціалізація початкових задач для обчислювальних вузлів вилучаючи перші елементи з відсортованих списків очікуючих задач та вузлів, проставлення початкового часу, який на даний момент рівний 0, та обчислення часу очікуваного завершення виконання задачі. Структури з посиланням на задачу, обчислювальний вузол та даними про початок та завершення виконання задачі поміщаються у чергу з пріорітетом по найменшому часу завершення.
- 4. Взяти з пріорітетної черги задачу, яка буде найближчою по часу наступною виконаною задачею. Приняти час симуляції за час завершення

- взятої з черги задачі, додати задачу до списку виконаних задач разом із даними про час її завершення.
- 5. Якщо список очікуючих задач не пустий, то вилучити перший елемент, поставити час початку як час симуляції, обчислити час завершення та додати у чергу з прірітетом, поставивши обчислювальний вузол як перший вільний із відсортованого списка вузлів.
- 6. Якщо пріорітетна черга не пуста, то повернутися на крок 4.
- 7. Знайти у списку виконаних задач найпізніші повернені задачі для кожного з користувачів та повернути їх час завершення.

Рисунок 3.1 – Скріншот вікна з описом параметрів програми

На Рис. 3.1 зображено основний інтерфейс програми. Програма має деякі обов'язкові параметри та опціональні - тобто такі, для яких вписані значення за вмовчанням, але при потребі їх можна змінити.

Список обов'язкових параметрів:

- 1. $problem_size$ цей параметр відповідає за визначення розміру матриць, симуляція яких буде проводитись. Розмір визначається одним числом оскільки ми матриці вважаємо квадратними $N \times N$.
- 2. mips цей параметр приймає список чисел, які визначають кількість обчислювальних вузлів у розподіленому середовищі та їх потужності. Для простоти було вирішено приймати потужності як коефіцієн-

ти при деякій номінальній потужності, яка задається опціональним параметром $nominal_mips$. Наприклад параметри "1 1.5 5 6" задають 4 обчислювальних вузла з потужностями $1*nominal_mips$, $1.5*nominal_mips$, $5*nominal_mips$, $6*nominal_mips$

3. slices - параметер відповідає за вибір набору стратегій, симуляція яких буде проводитись. У випадку двох гравців це буде декартовий добуток цієї множини с собою.

Список опціональних параметрів:

- 1. *nominal_mips* задає номінальний множник потужностей ОВ. За вмовченням вибраний такий, що відповідає за множення матриць розмірів 2000 за 1.6 секунди, що відносно відповідає потужності одного ядра у сучасних комп'ютерах.
- 2. bandwidth регулює ширину канала для передачі даних з кожним OB.
- 3. ping виставляє штраф за з'єднання.
- 4. single булевий параметр $\{0,1\}$, який дозволяє проводити симуляції лише для одного користувача.
- 5. $task_priority$ визначає пріорітетність вибору задач. Може приймати 2 значення min чи max. При виборі min спочатку виконуються задачі з меншим обсягом обчислень, а для max навпаки з більшим. За вмовчуванням береться режим min.
- 6. $proc_priority$ аналогічно до $task_priority$ визначае правило вибору вільного процесора. Для min задача планується на вільний процесор з найменшою потужністю, для max з найбільшою.

3.2 Ілюстрація результатів симуляції

3.2.1 Симуляція для одного користувача

Симуляція для одного користувача в загальному випадку навіть не вважається грою, а більш схоже на звичайну оптимізаційну проблему. Проте графіки симуляцій для одного користувача можуть показати характер обробки задач при блочному розрізанню матриць.

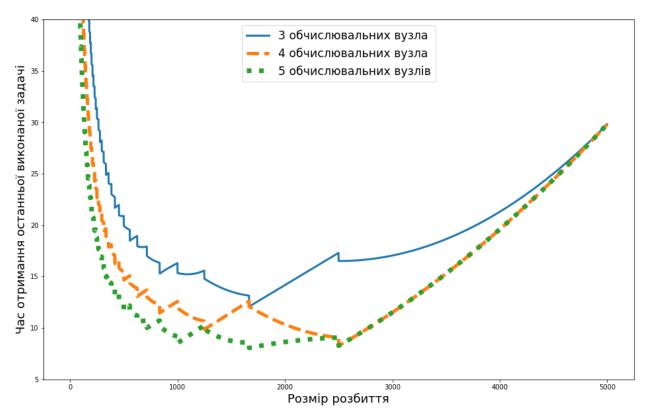


Рисунок 3.2 – Графік залежності часу виконання всіх задач користувача від розміру розрізання для різних кількостей обчислювальних вузлів

На Рис. 3.2 зображено залежність часу симуляції від розбиття при фіксованих N, latency, bandwidth для 3, 4 та 5 обчислювальних вузлів. Чим більше OB, тим швидше множення матриць, проте для деяких розрізань можна побачити майже однаковий час при різній кількості обчислювальних вузлів. Особливо це помітно для 4 та 5, починаючи з розміру розрізання 2500 час для них однаковий хоч для обчислень і задіяно більше OB.

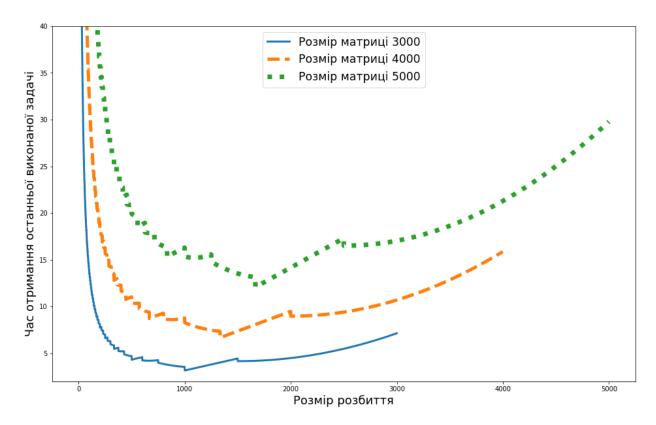


Рисунок 3.3 – Графік залежності часу виконання всіх задач користувача від розміру розрізання для різних розмірів матриць

На Рис. 3.3 показано для розмірів матриць 3000, 4000 та 5000 графіки залежності часу виконання усіх задач користувача від розбиття для 5 ОВ. З нього відносно можна помітити, що графіки мають приблизно однакову форму і можливо між ними має місце звичайна пропрорційну залежність від розміру матриці N.

3.2.2 Аналіз штрафів за розбиття

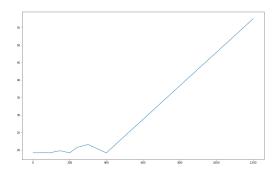
Також варто перевірити аналіз штрафів з теоретичного розділу за допомогою симуляційної системи. Це дуже просто зробити, оскільки програма дозволяє задавати деякі з параметрів як inf. 3 досліджувані параметри це: ping, bandwidth та mips. Якщо поставити $bandwidth = \inf \text{ ta } mips = \inf$, тоді складові часу, які відповідають за передачу даних та саме общичслення, обнуляться і ми будемо мати чисто лише час, який був спричинений затримками пакетів. Проводити експерименти будемо для конфігурацій із заниженими потужностями обчислювальних 3x вузлів 6e7 операцій/секунду, малим значенням пропускної здатності 8e7 біт/секунду та затримкою пакетів в 1 мілісекунду.

Таблиця 3.1 наглядно показує для випадку множення матриць розмірів 1200 штрафи. Також можемо побачити велику різницю мів розрізаннями 1200, 600 та 400. 1200 значить не розрізати матрицю та фактично виконати множення на одному ядрі, також час із першої колонки відповідає за чистий час обчислень без додавання часу пересилки та затримок. Час для розрізання 600 також ще поганий, оскільки було сформовано 4 задачі у той час як доступні всього 3 обчислювальних вузла. Тобто остання задача виконувалась лише на одному вузлі поки інші простоювали. Далі починаючи з розрізання 400 час відносно стабілізується. Це можна пояснити тим, що для наступних розрізань хоч і результуюча кількість задач може не бути дільником кількості обчислювальних вузлів, проте задачі вже настільки малі, що час простою в кінці значно менший ніж для випадків 1200 та 600. Також ці результати підтверджують теорію про те, що складність множення матриць ніяк не змінюється від щільності розбиття.

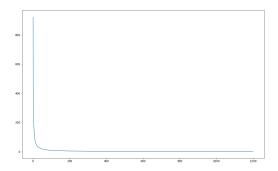
Таблиця 3.1 – Таблиця штрафів від величини розрізання

	processing time	transfer time	latency time	total
1	19.19200	921.98400	480.00000	1421.17600
2	19.19200	461.18400	120.00000	600.37600
3	19.19224	307.58784	53.33400	380.11408
4	19.19200	230.78400	30.00000	279.97600
5	19.19200	184.70400	19.20000	223.09600
6	19.19296	153.99170	13.33400	186.51866
8	19.19200	115.58400	7.50000	142.27600
10	19.19200	92.54400	4.80000	116.53600
12	19.19584	77.19944	3.33400	99.72928
15	19.19800	61.84332	2.13400	83.17532
16	19.19200	57.98400	1.87500	79.05100
20	19.19200	46.46400	1.20000	66.85600
24	19.20735	38.81503	0.83400	58.85638
25	19.19200	37.24800	0.76800	57.20800
30	19.21599	31.14288	0.53400	50.89287
40	19.19200	23.42400	0.30000	42.91600
48	19.25341	19.64667	0.20900	39.10908
50	19.19200	18.81600	0.19200	38.20000
60	19.28796	15.82272	0.13400	35.24468
75	19.34194	12.77100	0.08600	32.19894
80	19.19200	11.90400	0.07500	31.17100
100	19.19200	9.60000	0.04800	28.84000
120	19.57584	8.22528	0.03400	27.83512
150	19.79175	6.73200	0.02200	26.54575
200	19.19200	4.99200	0.01200	24.19600
240	20.72736	4.56192	0.00900	25.29828
300	21.59100	3.88800	0.00600	25.48500
400	19.19200	2.68800	0.00300	21.88300
600	28.78800	2.88000	0.00200	31.67000
1200	57.57600	3.45600	0.00100	61.03300

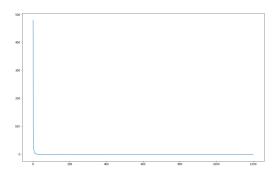
Розглянемо окремо графіки трьох складових загального часу: виконання задач, передачі даних та затримок.



(a) Графік часу обчислень від розміру розрізання



(б) Графік часу передачі даних від розміру розрізання



(в) Графік часу затримок від розміру розрізання

Рисунок 3.4 – Three subfigures

Також для кращого розуміння випадків розбиттів 1200, 600 та 400 варто проілюструвати процес виконання задач на блоках.

3.2.3 Симуляція для двої користувачів

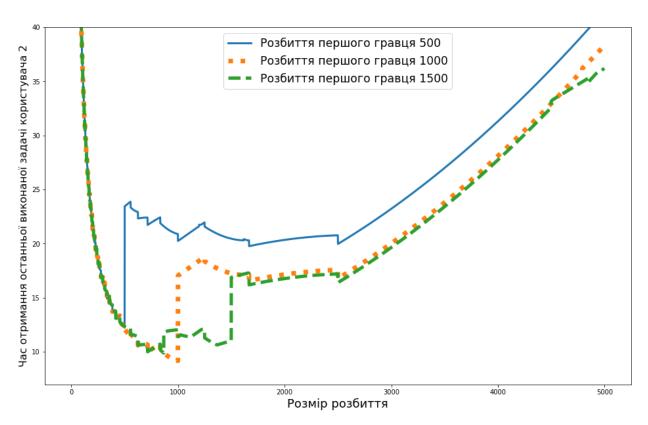


Рисунок 3.5 – Графік залежності часу виконання всіх задач другого користувача від розміру його стратегії розрізання при фіксованих стратегіях першого користувача

На Рис. 3.5 зображено залежність часу виконання усіх задач другого користувача від розміру розбиття при фіксованому розбитті користувача 1 для 5 ОВ. На графіку чітко спостерігається стрибки при переході розбиття користувача 2 за фіксоване значення розбиття користувача 1. Це особливість тіптіп та тіптах оскільки вони в першу чергу виконують найлегші задачі, тому користувач, що вибрав менше розбиття, має менший час виконання усіх його задач.

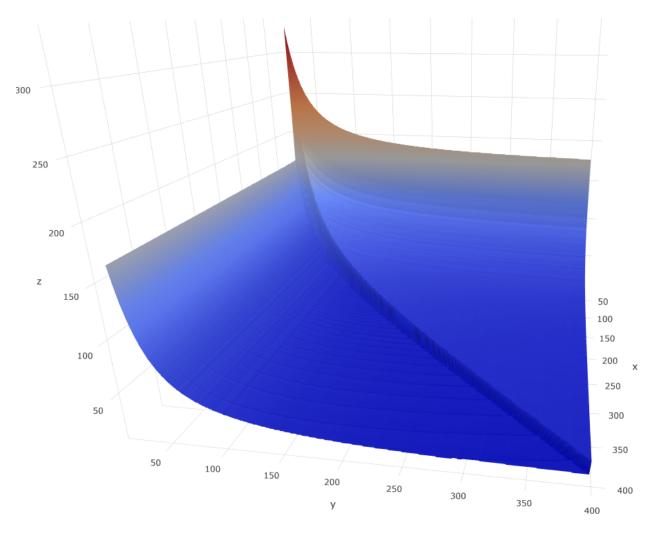


Рисунок 3.6 — Графік залежності часу виконання всіх задач другого користувача для всіх комбінацій стратегій обох користувачів з відрізка [20,400]

На перший погляд поверхя, яка отримана шляхом симуляції усіх можливих пар стратегій обох користувачів з відріка [20, 400], може здааватися гладкою та випуклою Рис. 3.6. Проте, пам'ятаючи природу графіків при фіксованій стратегії першого користувача на Рис. 3.5, слід подивитися на Рис. 3.6 більш ретельно, наприклад побудувати поверхню усіх комбінацій стратегій з відрізка [150, 350].

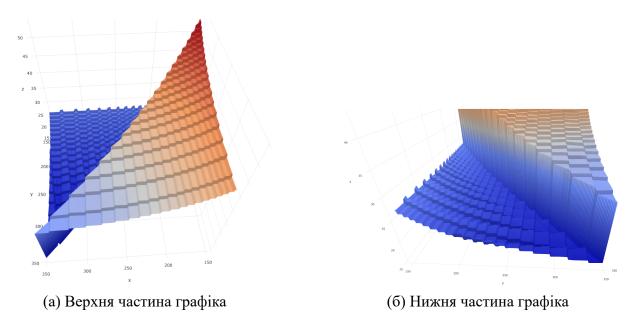


Рисунок 3.7 – Графік залежності часу виконання всіх задач другого користувача для всіх комбінацій стратегій обох користувачів з відрізка [150, 350], 3.7a - фокус на верхню частину поверхні, 3.76 - фокус на нижню частину поверхні

При кращій деталізації можна чітко побачити, що на Рис. 3.7a спостерігається форма сходинок по всій верхній частині графіка і вона не така проблемна, як нижня частина, показана на Рис. 3.76. Оскільки нижня частина більш цікава через те, що час завершення усіх задач користувача там менший, то і глобальний мінімум варто шукати саме на нижній частині. Нижня частина має особливої форми канави і саме вони є основною проблемою.

Таблиця 3.2 – Таблиця значень часів повернення усіх задач користувачів для різних стратегій розрізань

Slice First	Slice Second	Time First	Time Second
293	293	56.196913114	56.133074705
293	294	29.273646274	56.249161287
293	295	31.193692060	55.135836942
293	296	31.078784491	55.140002601
294	293	56.249161287	29.273646274
294	294	56.134305135	56.143839692
294	295	31.201760723	55.131381284
294	296	31.086853154	55.135546943
295	293	55.135836942	31.193692060
295	294	55.131381284	31.201760723
295	295	54.006477079	53.951126737
295	296	30.047061935	54.102473211
296	293	55.140002601	31.078784491
296	294	55.135546943	31.086853154
296	295	54.102473211	30.047061935
296	296	54.057876812	54.001345879

З Таблиці 3.2 можна побачити як в між деякими сусідніми значеннями спочатку час трохи збільшується, а потім різко зменшується. Таким чином структура функції і проблеми її оптимізації очевидні.

3.3 Застосування оптимізації до знаходження мінімуму

Спробуємо застосувати метод оптимізації з метою спуску до мінімуму. Перевіримо, що в залежності від початкової точки оптимізація буде застрягати у локальному мінімумі.

Застосуємо звичайний по координаті, яка зменшує час більше всього і запустимо його ітеративно.

На виході з симуляційної системи ми отримуємо квадратну матриці для обох гравців з їх часами отримання усіх задач. Позначимо їх так само як і у теоретичному розділі за $A,B\in\mathbb{R}^{N*N}$ як програші гравців 1 та 2 відповідно. Проте оскільки ми знаемо, що матриці при багаторазовому повторені експерименту та усереднені результатів, такі, що $A=B^T$. То будемо розглядати оптимізацію часу лише одного гравця, наприклад першого.

Нехай задана початкова точка (a_0,b_0) як початкові стратегії користувачів. З цієї точки стартує алгоритм.

Етапи роботи алгоритма спуску:

- 1. Задаємо початкову точку $p_0=(a_0,b_0)$, час у точці p_0 поставимо за $t_0=A_{a_0b_0}$. Поставимо k=0.
- 2. Шукаємо найменший час по квадрату зі сторонами в 3 елементи матриці і центром у точці p_k .
- 3. Вибираємо точку з найменшим часом та ставимо її як p_{k+1} . Якщо $p_{k+1} = p_k$, то зупиняємо алгоритм.
- 4. k = k + 1, повертаємося на крок 2.

Перевіримо як працює алгоритм. Для перевірки проведемо симуляцію для розміру матриць 10000 по розрізанням, які є дільниками 10000, нехтуємо розширенням симуляцій з блоками. Знайдемо глобальний мінімум та спробуємо запустити оптимізацію з різних стартових точок. Потужності обчислювальних вузлів поставимо у співвідношенні 2:2:1. Тобто три обчислювальних вузла.

Таблиця 3.3

No	Початкова стратегія	Початковий час	Кінцева стратегія	Кінцевий час
1.	(2,2)	6670.72055426	(1250, 2000)	11.0248749
2.	(10000,10000)	14.65571875	(5000,10000)	13.7184062
3.	(5,25)	1335.36618371	(1000,1250)	11.0248749
4.	(25,5)	1604.09384557	(1000,1250)	11.0248749
5.	(25,5)	1604.09384557	(1000,1250)	11.0248749
6.	(625,40)	184.069188072	(1000,1250)	11.0248749

Як бачимо з таблиці 3.3, оптимізація працює непогано в сенсі що дозволяє вибратись з неефективних точок. Проте оптимізація застрагяє і не дохо-

дить до глобального мінімума. І як ми пам'ятаемо за Рис. 3.7, при розгорнутій симуляції з розбиттями, які не є дільниками розмірності матриці, то там канави зустрічаються дуже часто, що говорить про повну неможливість використовувати методи оптимізації для знаходження оптимальної точки, проте у випадку дільників розмірності матриці оптимізація допомагає вибратись з поганих точок до відносно хороших, які по часу дуже близько до глобального мінімума.

Висновки до розділу

У цьому розділі були проведені експерименти за допомоги побудованої СПЗ. Ці експерименти дозволили перевірити основну модель на основі потокової та особливо характер штрафів.

За допомоги додаткової бібліотеки "nashpy" на мові Руthon було проведено пошук рівноваг за Нешем у грі двох користувачів та отримано результати.

РОЗДІЛ 4 Керування стартапом проекту

4.1 Опис ідеї проекту

Назва проекту - "Efficient task distribution for cloud computing". Проект являє собою систему, яка дозволяє правильно розбивати математичны задачі на підзадачі з метою мінімізації часу їх виконання у розподіленому середовищі.

Проект вирішує проблему виконання складних задач, які можна розділити на велику кількість простіших задач, у розподіленому середовищі з мінімізацією часу виконання задач для багатьох користувачів. В першу чергу така проблема може виникнути у дослідницьких центрах, де часто виконуються прості операції проте з неймовірно виликими обсягами даних. Часто такі задачі дуже легко розбивати на більш прості підзадачі, проте не завжди просто оцінити найефективнішу стратегію розбиття. На даний момент такі задачі вирішуються звичайним паралелізмом і такий метод відносно задовольняє потреби, проте основною метою проекта є пошук найефективніших шляхів паралельного виконання дрібних задач та використання симуляційних систем для аналізу ефективності розбиття задачі на підзадачі.

Таблиця 4.1 – Опис ідеї стартап-проекту

Зміст ідеї	Напрямки застосува-	Вигоди для користу-
	ння	вача
Розробка	1. У сфері досліджень	Можливість провести
симуляційної системи,	планувальників, пе-	симуляцію роботи
яка допоможе	ревірка теорій, аналіз	cloud системи із засто-
симюлювати	особливостей плану-	суванням вибраного
обчислення у Cloud	вальників	планувалника без
системі за значно		значних затрат часу чи
коротший час без		грошей
застостування	2. Проведення дослі-	Симуляція роботи
додаткових	ждень задач та знахо-	cloud системи при
обчюслювальних	дження найефективні-	великих обсягах задач
машин.	ших розбиттів.	за значно коротший
		час

Таблиця 4.2 – Визначення сильних, слабких та нейтральних характеристик ідеї проекту

New Market	Техніко- економічні характери- стики ідеї	(потенп	ійні) товар конкурен	(потенційні) товари/концепції конкурентів	: =	W (слабка сторона)	N (ней- тральна сторона)	S (сильна сторона)	
		Мій про- ект	Cloud Sim	Grid Sim	Amazon AWS				
<u> </u>	Швидка си- муляційна	продукт на мові	бібліо- тека на	бібліотека на Јаvа	повно-	потребує ретельного	доступна платфор-	дозволяє оцінити	базово ефе-
	система	C++	Java		бна	аналізу cloud	ма для	ктивність	cloud
					система	систем	наукових	системи	
					-иь90		дослі-		
					слень		джень		
							плану-		
							вальни-		
2	Ефективна	додаткові	1	ı	-9odeod	потребуе зна-	- CIVI	ДОЗВОЛЯЄ	значно
	аналітика	функції			ка вла-	чних витрат у		прискорити	-90
	паралельних	-оп впд			сного	дослідження		числення,	Що
	алгоритмів	шуку			пакету			у май	майбутньо-
		опти-			аналіти-			му доз	дозволить
		мальних			КИ			економити	на
		конфі-						обчисленнях	X y
		гурацій						cloud системах	мах
		алгори-							
		тма							

Таблиця 4.3 — Технологічна здійсненність ідеї проекту

№	Ідея проекту	Технології її ре-	Наявність	Доступність
п/п		алізації	технологій	технологій
1	Побудова си-	На мові С++	Технологію	Технології
	муляційної	реалізація	потрібно доро-	доступні усім
	системи для те-	системи, що	бити, сама ідея	користувачам
	стування cloud	аналогів по	протестована і	
	систем	швидкодії для	показує непо-	
		якої немає	гані результати	
			по швидкодії,	
			потрібно лише	
			розширити її	
			можливості	
2	Аналіз швидко-	Залучення	Не наявні, по-	Доступні
	дії паралельних	команди ма-	трібно запуска-	
	алгоритмів у	тематиків до	ти процес з нуля	
	cloud системах	аналізу най-		
		популярніших		
		планувальників		
		та побудови		
		математи-		
		чних моделей		
		основних за-		
		дач з лінійної		
		алгебри		

4.2 Аналіз ринкових можливостей запуску стартап-проекту

Таблиця 4.4 — Попередня характеристика потенційного ринку стартаппроекту

No	Показники стану рин-	Характеристика
	ку(найменування)	
1	Кількість головних гравців,	3
	од.	
2	Загальний обсяг гравців, \$	4.5 млрд.
3	Динаміка ринку	Попит зростає,
		пропозиція майже
		не збільшується
4	Обмеження для входу на	Наявність якісно-
	ринок	го програмного
		продукту
5	Специфічні вимоги до стан-	Відсутні
	дартизації та сертифікації	
6	Середня норма рентабель-	100%
	ності в галузі	

Таблиця 4.5 – Характеристика потенційних клієнтів стартап-проекту

№	Потреба, що	Цільова ауди-	Відмінності	Вимоги кори-
п/п	формує ринок	торія(цільові	у поведінці	стувачів до
		сегменти рин-	різних по-	товару
		ку)	тенційних	
			цільових груп	
1	Необхідність	Дослідницькі	У різних цен-	Простота у
	аналізу різних	центри та	трах чи уні-	використанні
	планувальників	університети	верситетах	та достатня
	з метою побудо-		проводяться рі-	швидкодія
	ви та перевірки		зні дослідження	для перевірки
	математичних		i	гіпотез
	моделей			
2	Симуляція	Університети,	Кожна окрема	Симуляційна
	ресурсоємних	дослідницькі	задача потребує	система по-
	задач з роз-	центри та ком-	особливий ана-	винна бути
	биттям їх на	панії, які хочуть	ліз та алгоритм	достатньо уні-
	підзадачі	збільшити	розбиття	версальною
		ефективність		оскільки задачі
		обчислень		можуть бути
				не лише чисто
				математичні

Таблиця 4.6 – Фактори загроз

№ п/п	Фактор	Зміст загрози	Можлива реакція компанії
1	Платформи для хмарних обчислень розробляють функцію симуляції обчислень за значно меншою ціною	симуляції на платформах хмар-	Перегляд цін на підписки, покращення співпраці з обчислювальними центрами та надання додаткових послуг по аналізу моделей задач
2	Поява продукту з аналогічною швидкодією та відкритим кодом	Приводить до повного знецінення товару оскільки відкритий код означає, що продукт доступний усім безкоштовно	Розробка дода- ткових функцій та графічно- го інтерфейсу для полегшення процесу роботи з програмним продуктом

Таблиця 4.7 – Фактори можливостей

№ п/п	Фактор	Зміст можливості	Можлива реакція компанії
1	Співробітництво з платформами хмарних обчислень	Можливість про- сування продукта напряму на пла- тформах завдяки угоді з компанія- ми провайдерами хмарних обчи- слень	Значні збільшення продажів підписок та простіша реклама
2	Збільшення попиту на складні обчислення	Можливість швидкого росту завдяки аналізу популярних високонавантажених алгоритмів	Збільшення продажів

Таблиця 4.8 – Ступеневий аналіз конкуренції на ринку

№ п/п	Особливості кон-	В чоему проявляє-	Вплив на діяль-
	куретного середо-	ться дана характе-	ність підприєм-
	вища	ристика	ства
1	Олігополія	Існують від-	Задають стантарт
		риті системи	програмного за-
		- CloudSim та	безпечення для
		GridSim	симуляцій хмар-
			них обчислень
2	Міжнародний рі-	Цифрові продукту	Універсальність
	вень конкуретної	інформаційного	продукту та
	боротьби	пошуку не мають	швидкодія
		кородонів	
3	Галузева конку-	Конкуренція про-	Надавати висо-
	ренція	ходить у галузі	коефективний
		аналізу паралель-	продукт для ана-
		них алгоритмів	лізу складних
			задач
4	Товарно-видова	Наявність фун-	Спостереження за
	конкуренція за	кцій для повно-	Cloud системами
	видами товарів	цінної симуляцій	да додавання
		Cloud системи	нових функцій
5	За характером	В першу чергу ва-	Розширення фун-
	конкурентних	жливі швидкодія	кціоналу, додава-
	перваг: нецінова	та універсальність	ння нових моде-
			лей у продукт
6	За інтенсивні-	На ринку я ана-	
	стю - марочна	логічні продукти	
	конкуренція	зі схожим фун-	продукт
		кціоналом, проте	
		їх швидкодія	
		недостатня для	
		серйозних дослі-	
		джень	

Таблиця 4.9 – Аналіз конкуренції за М. Портером (Висновки)

Назва характеристики	Характеристика
Прямі конкуренти	Cloudsim Plus
Потенційні конкуренти	Goolgle, Microsoft, Amazon AWS, Digital Ocean
Постачальники	Amazon, Digital Ocean, Google
Клієнти	KPI, Amazon, інші університети
Товари-замінники	CloudSim, GridSim, CloudSim Plus

Таблиця 4.10 – Аналіз конкуренції за М. Портером (Складові аналізу)

Назва характеристики	Характеристика		
Прямі конкуренти	Прямі конкуренти - дрібні компанії		
Потенційні конкуренти	Потенційні конкуренти - компанії-гіганти		
Постачальники	Постачальники хмарних обчислень - потенцій-		
	ні конкуренти		
Клієнти	Для клієнтів продуктивність паралельного ал-		
	горитма - основна проблема		
Товари-замінники	Товари-замінники працюють дуже повільно та		
	непридатні для складних симуляцій		

Таблиця 4.11 – Обгрунтування факторів конкурентноспроможності

що ро- я кон- щим) ніж у ві Java овува- ні пла- усиль
щим) ніж у ві Java овува- ні пла-
ніж у ві Java овува- ні пла- усиль
ві Java овува- ні пла- усиль
овува- ні пла- силь
ні пла-
/силь
проду-
потре-
ліз рі-
ою ім-
Також
проду-
ся по-
ити на
уктури
ї скла-

Таблиця 4.12 – Порівняльний аналіз сильних та слабких сторін

#	Dayton kayyyayyayyyaati			Рейт	гинг	,			
#	Фактор конкурентноспроможності	Бали]	відн	осно)			
		1-20	Cloudsim Plus						
			-3	-2	-1	0	1	2	3
1	Швидкодія	20							+
2	Готова база простих планувальників	20							+
3	Простота використання	15						+	
3	Універсальність	15		+					

Таблиця 4.13 – SWOT- аналіз стартап-проекту

Сильні сторони:

- Висока швидкодія у порівнянні з аналогічними продуктами
- Вбудовані прості планувальники, які легко використовувати
- Простота бібліотеки

_ _ . .

Можливості:

- Інтеграція у реальні Cloud системи з метою попереднього аналізу задачі перед саме замовленням хмари
- Проводити дослідження планувальників
- Просте тестування математичних моделей оскільки симуляції достатньо швидкі

Слабкі сторони:

- Недостатня універсальність оскільки продукт лише у початковому виді
- Продукт постачається мовою С++, яка вважається складнішою за Java для людей, які більше математики ніж програмісти

Загрози:

- Компанії гіганти можуть випустити власне програмне забезпечення для попереднії симуляцій
- Існуючі продукти у розробці також можуть активізуватися та спробувати конкурувати на ринці
- Поява нових конкурентів з поріняно схожою швидкодією програмного продукту

Таблиця 4.14 – Альтернативи ринкового впровадження стартап-проекту

№ п/п	Альтернатива	Ймовірність отри-	Строки реалізації
	(орієнтований	мання ресусрів	
	комплекс захо-		
	дів) ринкової		
	поведінки		
1	Розробка АРІ	0.9	0.5 року
	для інших мов		
	програмування		
	з метою полег-		
	шення процесу		
	використання		
	програмного		
	продукту		
2	Додавання специ-	0.4	0.5 року
	фічних плануваль-		
	ників у симуляцій-		
	ну систему		
3	Побудова матема-	0.4	2 роки
	тичних моделей		
	популярних задач		
	лінійної алгебри		

4.3 Розробка ринкової стратегії проекту

Таблиця 4.15 – Вибір цільових груп потенційних споживачів

Ma	Orma	Готоругот	Oniarrany	Termarraren	Песстана
№	Опис	Готовність	Орієнтовний .	Інтенсив-	Простота
$ \Pi/\Pi $	1 1	споживачів	помит ці-	ність кон-	входу у
	цільової	сприйти	льової групи	куренції в	сегмент
	групи по-	продукт	(сегменти)	сегменті	
	тенційних				
	клієнтів				
1	Універси-	Потребують	Університети	Конкуренція	Оскільки
	тети та до-	простого	потребують	із відкри-	існуючі рі-
	слідницькі	інтерфейсу	продукт для	тими	шення дуже
	центри	та високої	швидкої	безко-	повільні для
		швидкодії.	перевірки	штовними	випадків
		Оскільки	теорій. До-	рішен-	симуляції
		ці складо-	слідницькі	нями:	складних
		ві наявні,	центри -	CloudSim,	паралельних
		то спожи-	прискори-	CloudSim	задач, то вхід
		вачі будут	ти власні	Plus,	у сегмент
		задоволені	обчислення	GridSim	дуже легкий
2	Індиві- ду-	Потребують	Попит серед	Конкуренція	Вихід у цей
	альні кори-	простої бі-	користувачів	із відкри-	сегмент бу-
	стувачі	бліотеки з	Amazon	тими	де важчим
		інтуітивною	AWS,	безко-	оскільки
		структурою	Microsoft	штовними	існуючі рі-
		та універ-	Azure, Digital	рішен-	шення більш
		сальним	Ocean	нями:	універсальні
		дизайном		CloudSim,	та покрива-
				CloudSim	ють більшу
				Plus,	множину
				GridSim	задач

Таблиця 4.16 – Визначення базової стратегії розвитку

№ п/п	Обрана аль-	Стратегія	Ключові	Базова стра-
	тернатива	розвитку	конкуретно-	тегія розви-
	розвитку	ринку	спроможні	тку
	проекту		позиції від-	
			повідно	
			до обраної	
			альтернативи	
1	Набір основ-	На початко-	Наявність	Просування
	ної маси ко-	вих етапах	простого	продукту
	ристувачів	давати уні-	інтерфейсу	завдяки
		верситетам	та швидкої	науковим пу-
		можливість	симуляційної	блікаціям, які
		користува-	системи	використо-
		тися без-		вують даний
		коштовно		програмний
		продуктом		продукт
2	Розвиток	Додавання	Розповсю-	Популяризація
	симуляційної	популярних	дженість	програмного
	системи	алгоритмів	та проста	продукту
		планування,	інтеграція	та введення
		прикладів	для будь-якої	підписок
		аналізу моде-	популярної	
		лей простих	платформи	
		математи-		
		чних задач		

Таблиця 4.17 — Визначення базової стратегії конкурентної поведінки

№ п/п	Чи є проект	Чи буде	Чи буде	Стратегія
	першопро-	компанія	компанія	конкурентної
	хідцем на	шукати нових	копіювати	поведінки
	ринку	споживачів	основні хара-	
		чи забирати	ктеристики	
		існуючих у	товару кон-	
		конкурентів	курента і	
			які?	
1	Проект не ϵ	Компанія в	Компанія	Компанія
	першопро-	першу чергу	має на меті	надає схожий
	ходцем	буде забирати	в спочатку	продукт,
		споживачів	реалізувати	проте у
		існуючих	аналогічний	більш зру-
		продуктів	функціонал	чній формі
			як в існуючих	та із зна-
			продуктах	чно кращою
				швидкодією

Таблиця 4.18 — Визначення стратегії позиціонування

№ п/п	Вимоги до то-	Базова стра-	Ключові кон-	Вибір асоціа-
	вару цільової	тегія розви-	курентоспро-	цій, які мають
	аудиторії	тку	можні позиції	сформувати
			власного	комплексну
			стартап-	позицію
			проекту	власного
				проекту (три
				ключових)
1	Висока швид-	Розробка си-	Значно вища	Швидкодія,
	кодія, яка	стеми на мо-	швидкодія	простота ви-
	дозволить	ві С++ яка до-	порівняно з	користання,
	проводити	зволить про-	аналогами та	оптимізація
	експери-	водити швид-	більш зру-	паралельних
	менти у	кі та точні си-	чний процес	алгоритмів
	системі зна-	муляції	аналізу алго-	
	чно швидше		ритмів у cloud	
	ніж у реаль-		системах	
	них cloud			
	системах			

4.4 Розроблення маркетингової програми стартап-проекту

Таблиця 4.19 — Визначення ключових переваг концепції потенційного товару

№ п/п	Потреба	Вигода, яку	Ключові переваги
	1	пропонує товар	перед
			конкурентами
1	Можливість	Товар надає	Конкуренти хоч і
	провести	можливість	надають товари з
	експерименти з	проводити серії	більшим
	різними	симуляцій	функціоналом,
	структурами cloud	обчислень,	проте симуляція
	систем перед	оцінити	складних задач
	власне	ефективність	проходить дуже
	замовленям	структури cloud	довго
	системи	системи	, ,
2	Збільшення	Продукт дозволяє	Конкуренти не
	ефективності	симулювати	надають таких
	паралельних	процес обчислень	послуг
	алгоритмів	та знаходити	
	_	оптимальні	
		параметри	
		алгоритма для	
		певної структури	
		cloud системи	
3	Дослідницька	СПЗ надає	ПП конкурентів
	діяльність у сфері	можливість	непридатний до
	хмарних	практично	дослідження ви-
	обчистень	перевіряти	соконавантажених
		гіпотези чи	сценаріїв
		проводити	
		дослідження	
		емпіричним	
		ХЛЯХОМ	

Таблиця 4.20 – Опис трьох рівнів моделі товару

	T.					
Рівні товару	Сутність та складові					
I. Товар за за-	Задовольняє потреб	бу у швидкому СПЗ	, яке дозволить			
думом	ефективно проводити симуляції складних сценаріїв на-					
	віть на простих пор	тативних комп'ютер	ax			
II. Товар у	Властивості / ха-	астивості / ха- М/Нм Вр/Тх /Тл/Е/Ор				
реальному	рактеристики					
виконанні						
	1. Висока швидко-					
	дія					
	2. Простота поши-					
	рення					
	3. Низька вартість	Ь				
	обслуговування					
	Якість: продукт над	цає високу швидкодін	о симуляцій на-			
	віть на непотужних	комп'ютерах				
	Пакування: продукт	г розповсюджюється	дистрибутивно			
	Марка: HighLoadCo	отр, назва товару - Н	IighLoadSim			
III. Товар із	До продажу:	базова симуляційн	а система + під-			
підкріплен-		тримка кліентів				
НЯМ						
	Після продажу:	СПЗ з додатковими послугами роз-				
		робки ефективного паралельного ал-				
		горитма				
За рахунок чого потенційний товар буле захишено віл копіювання: ла-						

За рахунок чого потенційний товар буде захищено від копіювання: даний продукт легко скопіювати, проте оскільки захист коду можливий, то значить для копіювання потрібно буде розробляти СПЗ з нуля, що тягне за собою великі затрати на розробку

Таблиця 4.21 – Визначення меж встановлення ціни

№ п/п	Рівень цін	Рівень цін	Рівень дохо-	Верхня та
	на товари-	на товари-	дів цільової	нижня межі
	замінники	аналоги	групи спожи-	встановлення
			вачів	ціни на това-
				р/послугу
1	Товари замін-	Товари	Рівень дохо-	Верхня межа
	ники - ХС,	аналоги без-	дів студентів	3 \$, верхня 5\$
	рівень цін на	коштовні,	та викладачів	за підписку
	які достатньо	проте вони	низький	
	високий	не підходять		
		для симуляції		
		високона-		
		вантажених		
		сценаріїв		

Таблиця 4.22 — Формування системи збуту

№ п/п	Специфіка	Функції збу-	Глибина	Оптимальна
	закупівельної	ту, які має	каналу збуту	система збуту
	поведінки	виконувати		
	цільових	постачальник		
	клієнтів	товару		
1	Велика	(не застосову-	1	Збут через
	кількість	ϵ ться $)$		онлайн-
	поодиноких			системи чи
	клієнтів ко-			співпрацю з
	ристується			університета-
	сервісом			МИ
	та з часом			
	кількість			
	користувачів			
	збільшуєтсья			
	(оскільки			
	заощаджу-			
	ють обидві			
	сторони)			

Таблиця 4.23 – Концепція маркетингових комунікацій

№	Специфіка	Канали ко-	Ключові по-	Завдання	Концепція
п/п	поведінки	мунікацій,	зиції, обрані	рекламного	рекламного
	цільових	якими ко-	для позиціо-	повідомле-	звернення
	клієнтів	ристуються	нування	ння	
		цільові клієн-			
		ти			
1	Поступово	Внутрішня	Заощадження	Поширити	Рекламу кра-
	вводиться	система ко-	на дослідже-	інформа-	ще проводити
	сервісний	мунікацій	ннях такого	цію про	через універ-
	збір за	через серві-	складного	СПЗ, яке	ситети чи
	користува-	сну систему	середовища	надає зна-	дослідницькі
	ння чисто		як ХС	чно більшу	центри, які
	онлайн			швидкодію	проводять
	системою			та просте	досліджен-
				у викори-	ня у сфері
				станні	хмарних
					обчислень

Висновки до розділу

Дана магістерська дисертація має перспективи зростання до популярного продукту у сфері хмарних обчислень. Існуючі бібліотеки хоч і доступні беспоштовнопроте мають дуже низьку швидкодію, яка взагалі не дозволяє проводити повномаштабні експерименти з метою оцінки її майбутньої продуктивності.

Розробка продукту не потребує значних вкладів, оскільки для написання проекту достатньо і трьох досвідчених програмістів. Після завершення основної фази розробки та початку реклами проекту. Спочатку краще всього зробити деяку версію продукту для університетів та студентів, оскільки саме для них в першу чергу може бути корисним цей продукт.

Складнощі в першу чергу можуть бути через недостатню універсальність на початкових етапах релізу продукту та можливу пожвавлену конку-

ренцію на етапі виходу на ринок. Також конкуренти з великою кількістю ресурсів можуть розпочати розробку власного продукту, що може сильно вплинути на подальший розвиток стартапа. Такі випадки часто трапляються в ІТ сфері.

Проте часто великим компаніям дешевше купити невелику компанію чи стартап, та інтегрувати їх продукт у свою інфраструктуру, якщо якість продукту на достаньому рівні та задоволняє основні потреби користувачів. Ми вважаємо, що такий сценарій буде найкращим із усіх можливих, оскільки значно полегшить рекламу та дистрибуцію СПЗ.

ВИСНОВКИ ПО РОБОТІ ТА ПЕРСПЕКТИВИ ПОДАЛЬШИХ ДОСЛІДЖЕНЬ

У роботі проведено аналіз задачі множення матриць методом побудови потокової моделі для оцінки часу виконання задач одного користувача, а далі узагальнено для двох користувачів. Також чітко показано, що складність обчислень не збільшується в залежності від кількості ОВ, їх потужностей та інших параметрів ХС. Показано як впливає розмір розбиття на величину штрафів за пересилки. Також ця методологія може бути використана для аналізу інших задач, наприклад основних сценаріїв стантарта BLAS (Basic Linear Algebra Subprograms), які є основою усіх наукових обчислень навіть у великих проектах.

Розроблено СПЗ, яке дозволяє дуже швидко емулювати процес множення матриць з використанням одного із чотирьх статичних планувальників: minmin, minmax, maxmin та maxmax. Також це СПЗ універсальне та допускає розширення, удосконалення з можливістю переходу у реальний продукт, на базі якого можливо буде емпірично визначати параметри розбиття чи перевірки інших математичних моделей задач.

У подальшому також можна розглянути двох гравців як незалежні штучні інтелекти, які навчаються вибирати розрізання, та мають єдиний сигнал зворотнього зв'язку - час отримання усіх своїх задач. Таким чином можна дослідити деякі алгоритми навчання з підкріпленням, оскільки це добре підходить під концепцію гри де виграші на момент t якраз і будуть зворотнім сигналом. Основними алгоритмами у цій сфері ϵ : Q-learning, SARSA, DQN, DDPG.

ПЕРЕЛІК ПОСИЛАНЬ

- 1. CloudSim: A Framework For Modeling And Simulation Of Cloud Computing Infrastructures And Services. [Електронний ресурс]. Режим доступу: http://www.cloudbus.org/cloudsim/.
- 2. CloudSim Plus: A modern, full-featured, highly extensible and easier-to-use Java 8 Framework for Modeling and Simulation of Cloud Computing Infrastructures and Services. [Електронний ресурс]. Режим доступу: http://cloudsimplus.org/.
- 3. <u>Mayanka, Katyal</u>. Application of Selective Algorithm for Effective Resource Provisioning In Cloud Computing Environment / Katyal Mayanka, Atul Mishra // <u>International Journal on Cloud Computing</u>: Services and Architecture (IJCCSA). 2014. 2. Vol. 4, no. 1. Pp. 1–10.
- 4. <u>Srinivasa Prasanna, G. N.</u> Generalised Multiprocessor Scheduling Using Optimal Control / G. N. Srinivasa Prasanna, Bruce R. Musicus // SPAA. 1991.
- 5. <u>Smith, Tyler Michael</u>. Pushing the Bounds for Matrix-Matrix Multiplication / Tyler Michael Smith, Robert A. van de Geijn // <u>FLAME Working Not</u>. 2017. 2. no. 83. Pp. 1–11.
- 6. <u>Hong, Jia-Wei</u>. I/O complexity: The red-blue pebble game / Jia-Wei Hong, Hsiang-Tsung Kung // <u>Proceedings of the thirteenth annual ACM symposium</u> on Theory of computing. 1981. Pp. 326–333.
- 7. <u>Irony, Dror.</u> Communication Lower Bounds for Distributed-Memory Matrix Multiplication / Dror Irony, Sivan Toledo, Alexander Tiskin // <u>Journal of Parallel and Distributed Computing</u>. 2004. 09. Vol. 64. Pp. 1017–1026.
- 8. Coded Computation over Heterogeneous Clusters / Amirhossein Reisizadehmobarakeh, Saurav Prakash, Ramtin Pedarsani, Salman Avestimehr // arXiv. 2017. 01.
- 9. Coded computation for multicore setups / Kang Wook Lee, Ramtin Pedarsani, Dimitris Papailiopoulos, Kannan Ramchandran / IEEE International Symposium on Information Theory (ISIT). 2017. 06. Pp. 2413–2417.
- 10. Дорошенко, А.Ю. ПРО ОДНУ МОДЕЛЬ ОПТИМАЛЬНОГО РОЗ-ПОДІЛУ РЕСУРСІВ У БАГАТОПРОЦЕСОРНИХ СЕРЕДОВИ-

- ЩАХ / А.Ю. Дорошенко, О.П. Ігнатенко, П.А. Іваненко // <u>Проблеми</u> програмування. 2011. № 1. С. 21–28.
- 11. Nazarathy, Y. A Fluid Approach to Large Volume Job Shop Scheduling / Y. Nazarathy, G. Weiss // Journal of Scheduling. 2010. 5. no. 13. Pp. 509–529.
- Daskalakis, Constantinos. The Complexity of Computing a Nash Equilibrium / Constantinos Daskalakis, Paul Goldberg, Christos H. Papadimitriou. 2009.
 02. Vol. 39. Pp. 195–259.
- 13. Algorithmic Game Theory / Noam Nisan, Tim Roughgarden, Eva Tardos, Vijay V. Vazirani. New York, NY, USA: Cambridge University Press, 2007. P. 775.
- 14. <u>Бланк, С.</u> Стартап. Настольная книга основателя / С. Бланк, Б. Дорф. 2 изд. Москва : Альпина Паблишер, 2014. С. 614.
- 15. <u>Дрейпер, У.</u> Стартапы: профессиональные игры Кремниевой долины / У. Дрейпер. 2 изд. Москва: Эксмо, 2012. С. 378.
- 16. <u>Тиль, П.</u> От нуля к единице : как создать стартап, который изменит будущее / П. Тиль, Б. Мастерс. Москва : Альпина паблишер, 2015. С. 188.
- 17. <u>Харниш, В.</u> Правила прибыльных стартапов : как расти и зарабатывать деньги / В. Харниш. Москва : Манн, Иванов и Фербер, 2012. С. 279.
- 18. <u>Квашнин, А.</u> Как продвигать проекты коммерциализации технологий: серия методических материалов «Практические руководства для центров коммерциализации технологий. проект EuropeAid «Наука и коммерциализация технологий. 2006.